



# Credit Card Approval Analysis and Predictive Modeling

การวิเคราะห์และการสร้างแบบจำลองคาดการณ์การอนุมัติบัตรเครดิต

DS512/513 Data Analytics

DS514/515 Data Science

นำเสนอโดย

อาทิตย์ บุรณสิงห์

ID: 68199160309



# Index of Contents

## **1. Introduction**

- Data Analytics Framework
- Data Science Framework

## **2. Problem Statement/Background**

- What do we know about?
- What problem are you trying to solve?
- What is the business problem?

## **3. Questions/Hypothesis**

- Analytical Questions
- Predictive Hypothesis (What can we predict?)

## **4. Data Sources/Attributes**

- Data sources and Collection
- Data cleaning and Preprocessing

## **5. Analysis/Model Development**

- Analytics Methodology
- Modeling Methodology

## **6. Findings and Insights**

- Business Insights
- Predictive Results

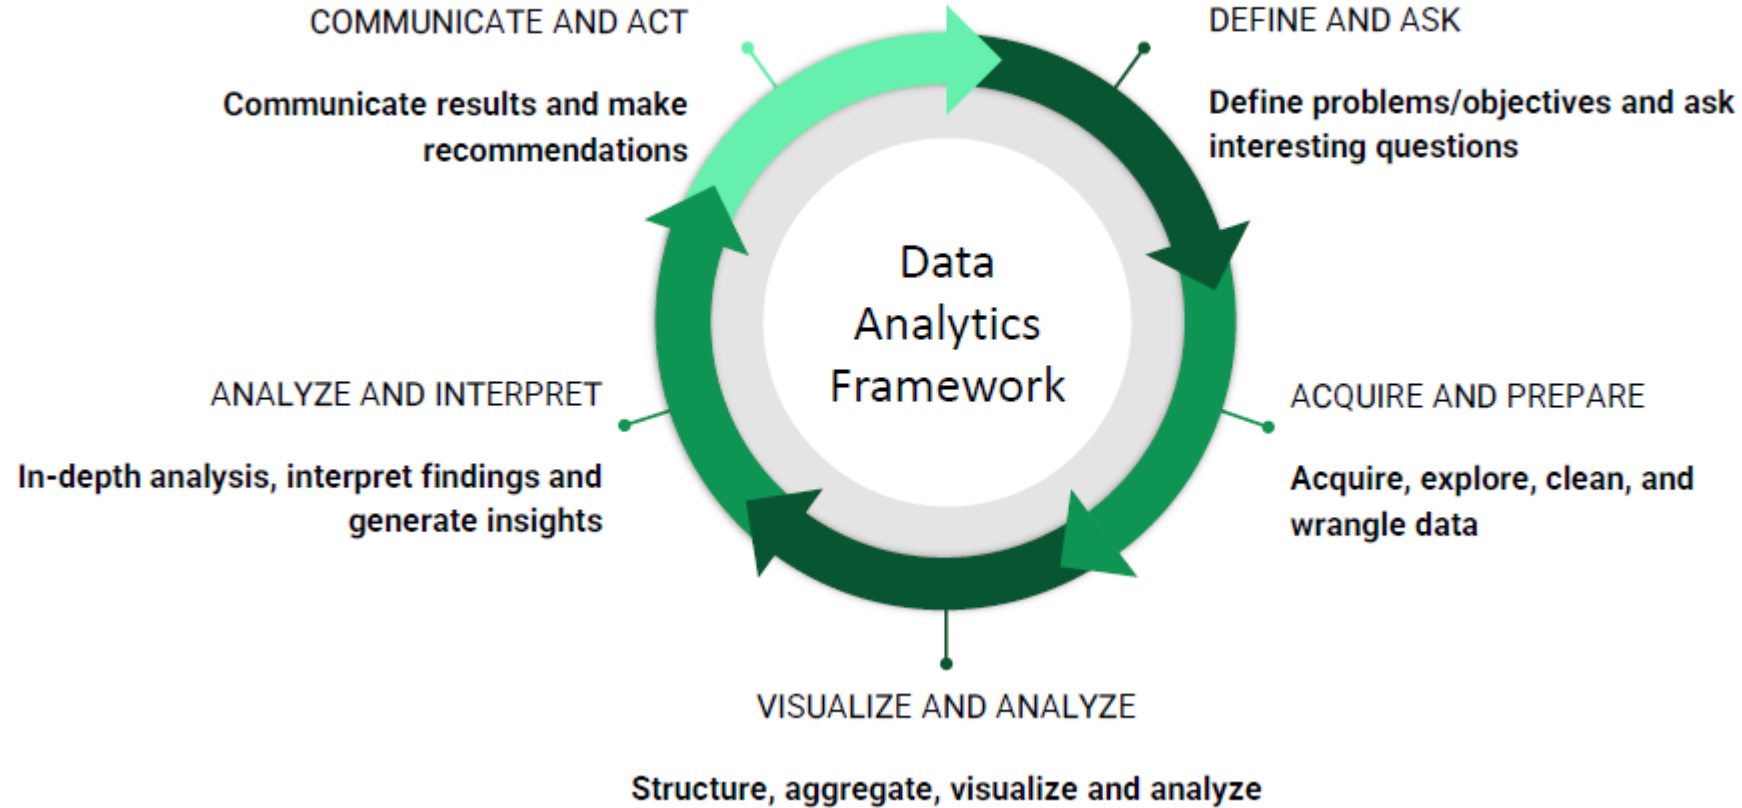
## **7. Conclusion and Recommendation/Action and Impact**

- What should we do with the findings?



## 1. Introduction

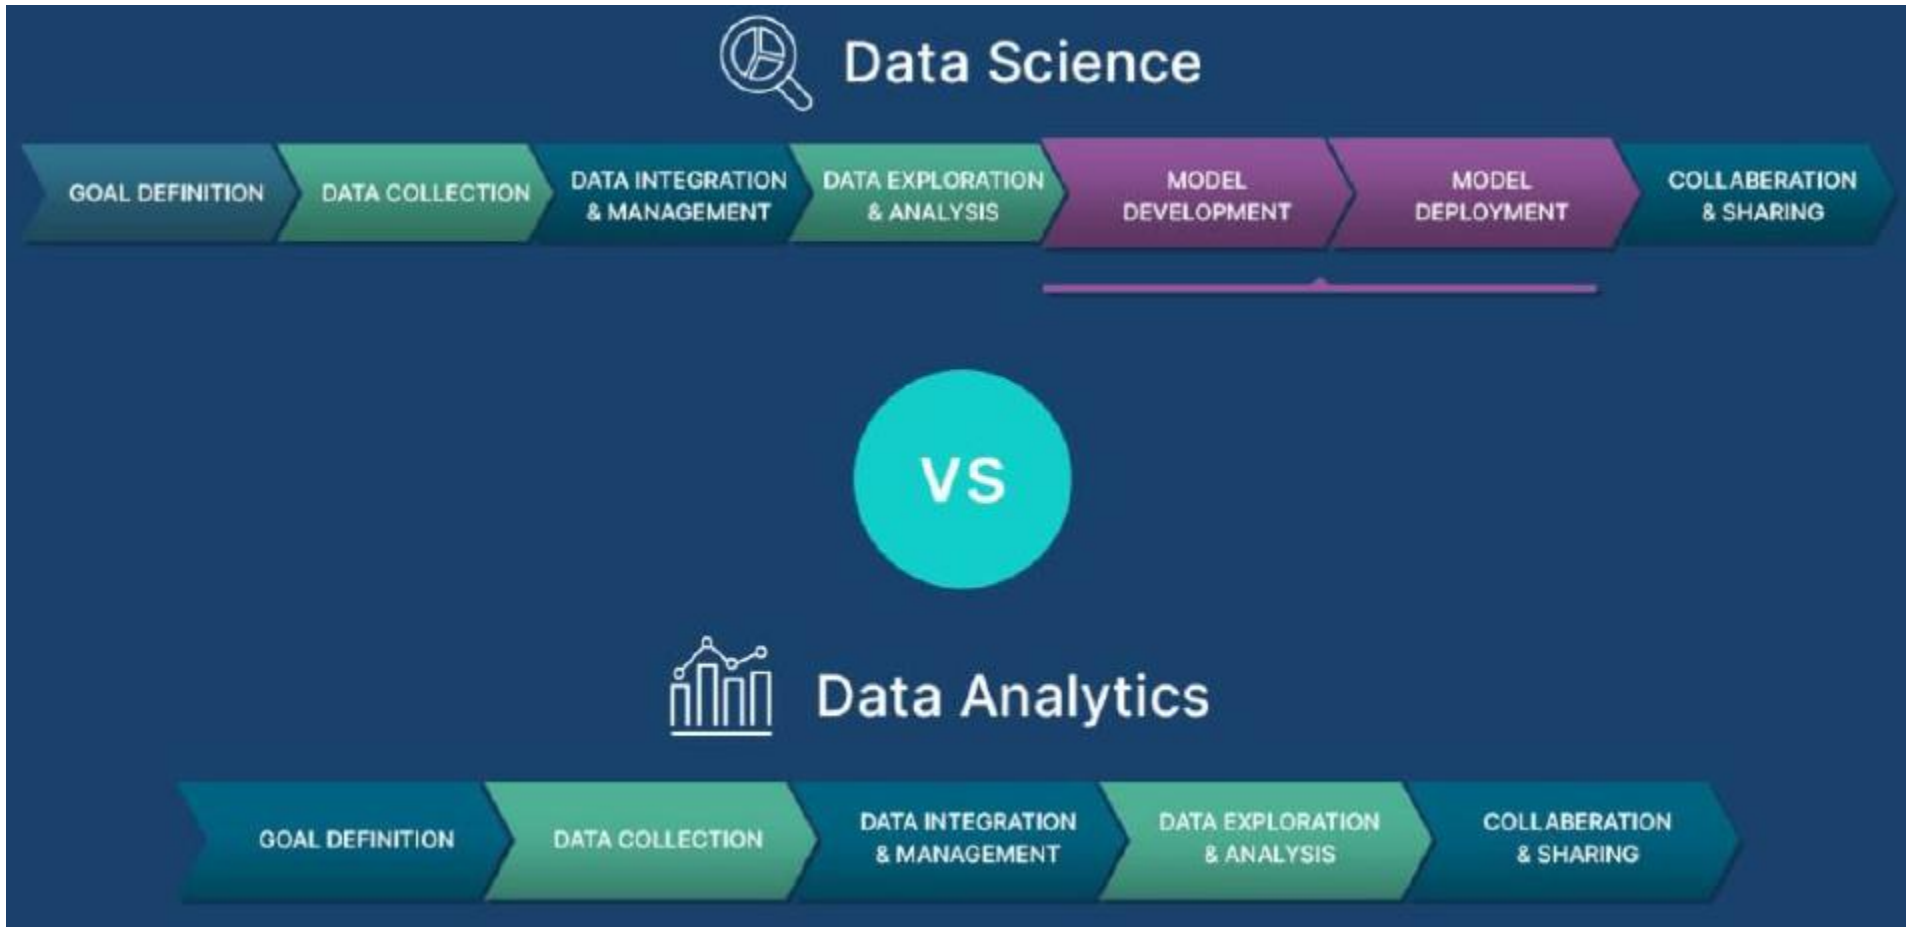
### Data Analytics Framework





## 1. Introduction

### Data Science Framework





1. Introduction

DATA PROJECT CANVAS

Title: Credit Card Approval Analysis and Predictive Modeling

<div><div>1. Problem Statement/Background</div><div><div>i</div><div></div></div><div><ul style="list-style-type: none"><li>What do we know about?</li></ul><p>สถาบันการเงินอนุมัติ/ปฏิเสธการสมัครบัตรเครดิต โดยพิจารณาจากข้อมูลผู้สมัคร โดยกระบวนการพิจารณาอาจใช้เวลานานและขึ้นอยู่กับดุลยพินิจของนักวิเคราะห์สินเชื่อ ซึ่งอาจนำไปสู่ความเสี่ยงหรือการสูญเสียโอกาสทางธุรกิจ</p><ul style="list-style-type: none"><li>What problem are you trying to solve?</li></ul><p>การสร้างแบบจำลองเพื่อทำนายผลการอนุมัติบัตรเครดิตโดยอัตโนมัติ เพื่อเพิ่มความรวดเร็วและความแม่นยำในการตัดสินใจ</p><ul style="list-style-type: none"><li>What is the business problem?</li></ul><p>การลดความเสี่ยงทางการเงิน (อัตราการผิดนัดชำระหนี้ - Default Rate) และเพิ่มประสิทธิภาพในการดำเนินงาน (Operational Efficiency) ของฝ่ายอนุมัติสินเชื่อ</p><ul style="list-style-type: none"><li>Who are the stakeholders?</li></ul><p>ธนาคาร/สถาบันการเงิน (ฝ่ายบริหารความเสี่ยง, ฝ่ายการตลาด, ฝ่ายปฏิบัติการ) ทีม Data Scientist/Analyst ผู้สมัครบัตรเครดิต</p></div></div>	<div><div>2. Questions/Hypothesis</div><div><div>?</div><div></div></div><div><ul style="list-style-type: none"><li>Analytical Questions</li></ul><p>- คุณลักษณะใดของผู้สมัคร (เช่น อายุ, รายได้, ประเภทงาน) ที่มีความสัมพันธ์กับการอนุมัติมากที่สุด?</p><p>- มีกลุ่มลูกค้า (Segments) ที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันชัดเจนหรือไม่? เกณฑ์การตัดสินใจแบบเดิมมีข้อบกพร่องตรงไหนบ้าง?</p><ul style="list-style-type: none"><li>Predictive Hypothesis (What can we predict?)</li></ul><p>- เราสามารถทำนายผลการอนุมัติบัตรเครดิต (Approved หรือ Rejected) จากข้อมูลของผู้สมัครที่ให้มาด้วยความแม่นยำสูง เพื่อช่วยในการตัดสินใจอัตโนมัติ</p><ul style="list-style-type: none"><li>SMART Objectives</li></ul><p>- เพิ่มยอดสินเชื่อ จากการอนุมัติบัตรเครดิต อย่างน้อย 5% ภายใน 1 ปี ด้วยการปรับกลยุทธ์ด้านสินเชื่อ</p></div></div>	<div><div>3. Value Propositions</div><div><div></div><div></div></div><div><ul style="list-style-type: none"><li>What are we trying to do for the end-user(s) of the system?</li></ul><p>มอบเครื่องมือในการตัดสินใจที่รวดเร็ว เป็นกลาง และสม่ำเสมอให้กับเจ้าหน้าที่สินเชื่อ ทำให้ผู้สมัครได้รับผลการตัดสินใจที่รวดเร็วยิ่งขึ้น</p><ul style="list-style-type: none"><li>What objectives are we serving?</li></ul><p>เพิ่มประสิทธิภาพการดำเนินงาน (ลดต้นทุนและเวลา) ปรับปรุงการประเมินความเสี่ยง (ลดหนี้เสีย) ขยายฐานลูกค้าอย่างมีคุณภาพ</p></div></div>	<div><div>4. Data Sources/Attributes</div><div><div></div><div></div></div><div><ul style="list-style-type: none"><li>Data sources &amp; collection</li></ul><p>- Kaggle Dataset: "Credit Card Approvals (Clean Data)" (ซึ่งจำลองมาจากการสมัครบัตรเครดิต)</p><p>- ข้อมูลในทางปฏิบัติ: ฐานข้อมูลภายในของธนาคาร/สถาบันการเงิน (ข้อมูลการสมัคร, ประวัติสินเชื่อ, ข้อมูลเครดิตบูโร)</p><ul style="list-style-type: none"><li>Data cleaning &amp; preprocessing</li></ul><p>- เนื่องจากเป็น "Clean Data" จะเน้นการตรวจสอบขั้นสุดท้าย การจัดการกับค่าที่หายไป (Missing Values) ที่ยังอาจมีอยู่</p><p>- การเข้ารหัสข้อมูลประเภท Categorical (เช่น One-Hot Encoding) การปรับขนาดข้อมูลตัวเลข (Normalization/ Standardization)</p><ul style="list-style-type: none"><li>Target variables &amp; feature</li></ul><p>- Target Variable: สถานะการอนุมัติ (Approved: '+', Rejected: '-')</p><p>- Features: คุณลักษณะของผู้สมัคร เช่น อายุ, รายได้, หนี้สิน, สถานภาพ, ประวัติเครดิต, ประเภทงาน (ตามคุณลักษณะใน Dataset)</p><ul style="list-style-type: none"><li>Encoding &amp; scaling strategies</li></ul><p>- Encoding: ข้อมูลที่ไม่ใช่ตัวเลข (Non-numerical/Categorical Data) ให้กลายเป็นตัวเลข โดยใช้เทคนิคที่เรียกว่า Label Encoding</p><p>- Scaling: Standard Scaler สำหรับตัวแปรตัวเลข (Numerical)</p></div></div>
<div><div>5. Analysis/Model Development</div><div><div></div><div></div></div><div><ul style="list-style-type: none"><li>Analytics Methodology</li></ul><p>- EDA techniques: การวิเคราะห์ความถี่และค่าสถิติเชิงพรรณนา (Univariate/Bivariate Analysis) เพื่อดูความสัมพันธ์ของแต่ละคุณลักษณะกับผลการอนุมัติ</p><p>- Visualization strategy: Heatmap สำหรับ Correlation Matrix</p><p>- Segmentation approach: การจัดกลุ่มลูกค้าตามโปรไฟล์ความเสี่ยง (Risk Profiles)</p><ul style="list-style-type: none"><li>Modeling Methodology</li></ul><p>- Algorithm selection: Classification Algorithms - Logistic Regression</p><p>- Training, hyperparameter tuning, evaluation metric:</p><p>** Training: แบ่งข้อมูลเป็น Training, และ Test Sets (Cross-Validation)</p><p>** Tuning: Grid Search เพื่อหา Hyperparameters ที่เหมาะสมที่สุด</p><p>Evaluation Metric: Accuracy, Precision, Recall, F1-Score</p></div></div>	<div><div>6. Findings and Insights</div><div><div></div><div></div></div><div><ul style="list-style-type: none"><li>Business Insights</li></ul><p>- คุณลักษณะหลักที่ขับเคลื่อนผลการอนุมัติ (Feature Importance)</p><p>- คำตอบ ปัจจัยด้าน ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผลการตัดสินใจอนุมัติบัตรเครดิต</p><p>- ระบุกลุ่มลูกค้าที่มีความเสี่ยงสูง/ต่ำ ที่ชัดเจนในชุดข้อมูล</p><p>* คำตอบ ข้อสรุปเชิงธุรกิจ: ปัจจุบัน Credit Score เป็นปัจจัยขับเคลื่อนหลัก (Primary Driver) ในกระบวนการอนุมัติ ทำให้เกิดการแบ่งกลุ่มลูกค้าเป็นสองขั้วอย่างมีประสิทธิภาพ</p><p>- แนวโน้มและรูปแบบของผู้สมัครที่ถูกอนุมัติ/ปฏิเสธ</p><p>* คำตอบ ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผลการตัดสินใจอนุมัติบัตรเครดิต ซึ่งตอบคำถามเชิงวิเคราะห์ที่ว่า "คุณลักษณะใดของผู้สมัครมีความสัมพันธ์กับการอนุมัติมากที่สุด"</p><ul style="list-style-type: none"><li>Predictive Results</li></ul><p>- ประสิทธิภาพของแบบจำลองที่ดี (F1-Score = 0.88)</p><p>- รายชื่อคุณลักษณะที่มีความสำคัญสูงสุด 4 อันดับแรกในการทำนายผล ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed)</p><p>- ผลการทดสอบกับ Test Set ที่ไม่ได้ใช้ในการฝึกฝน (Score = 0.88)</p></div></div>	<div><div>7. Recommendation/Action and Impact</div><div><div></div><div></div></div><div><ul style="list-style-type: none"><li>What should we do with the findings?</li></ul><p>- Action: นำแบบจำลองที่ปรับปรุงแล้วไปใช้งาน (Deploy) ในรูปแบบของ API หรือ Service เพื่อให้ระบบของธนาคารสามารถเรียกใช้ในการตัดสินใจอนุมัติเบื้องต้นโดยอัตโนมัติ</p><ul style="list-style-type: none"><li>What are the impacts?</li></ul><p>- Operational Impact: ลดเวลาในการตัดสินใจจากชั่วโมง/วัน เหลือเพียงวินาที</p><p>- Business Impact: ลดการเกิดหนี้เสีย (ลดความเสี่ยง) เนื่องจากมีความแม่นยำในการคัดกรองมากขึ้น และเพิ่มโอกาสในการอนุมัติลูกค้าที่มีคุณภาพเร็วขึ้น (เพิ่มกำไร)</p><p>- Customer Impact: ผู้สมัครได้รับผลการตัดสินใจรวดเร็วขึ้น ทำให้ประสบการณ์การใช้งานดีขึ้น</p></div></div>	



## 2. Problem Statement/Background

### 2. Problem Statement/Background

- **What do we know about?**

สถาบันการเงินอนุมัติ/ปฏิเสธการสมัครบัตรเครดิต โดยพิจารณาจากข้อมูลผู้สมัคร โดยกระบวนการพิจารณาอาจใช้เวลานานและขึ้นอยู่กับดุลยพินิจของนักวิเคราะห์สินเชื่อ ซึ่งอาจนำไปสู่ความเสี่ยงหรือการสูญเสียโอกาสทางธุรกิจ

- **What problem are you trying to solve?**

การสร้างแบบจำลองเพื่อทำนายผลการอนุมัติบัตรเครดิตโดยอัตโนมัติ เพื่อเพิ่มความรวดเร็วและความแม่นยำในการตัดสินใจ

- **What is the business problem?**

การลดความเสี่ยงทางการเงิน (อัตราการผิดนัดชำระหนี้ - Default Rate) และเพิ่มประสิทธิภาพในการดำเนินงาน (Operational Efficiency) ของฝ่ายอนุมัติสินเชื่อ

- **Who are the stakeholders?**

ธนาคาร/สถาบันการเงิน (ฝ่ายบริหารความเสี่ยง, ฝ่ายการตลาด, ฝ่ายปฏิบัติการ) ทีม Data Scientist/Analyst ผู้สมัครบัตรเครดิต



### 3. Questions/Hypothesis

### 3. Questions/Hypothesis

- **Analytical Questions**

- คุณลักษณะใดของผู้สมัคร (เช่น อายุ, รายได้, ประเภทงาน) ที่มีความสัมพันธ์กับการอนุมัติมากที่สุด?
- มีกลุ่มลูกค้า (Segments) ที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันชัดเจนหรือไม่? เกณฑ์การตัดสินใจแบบเดิมมีข้อบกพร่องตรงไหนบ้าง?

- **Predictive Hypothesis (What can we predict?)**

- เราสามารถทำนายผลการอนุมัติบัตรเครดิต (Approved หรือ Rejected) จากข้อมูลของผู้สมัครที่ให้มาด้วยความแม่นยำสูง เพื่อช่วยในการตัดสินใจอัตโนมัติ



## 4. Data Sources/Attributes

### 4. Data Sources/Attributes

- **Data Sources / Collection**

- **Kaggle Dataset:** "Credit Card Approvals (Clean Data)"  
(ซึ่งจำลองมาจากข้อมูลการสมัครบัตรเครดิต)

- **ข้อมูลในทางปฏิบัติ:**

- ฐานข้อมูลภายในของธนาคาร/สถาบันการเงิน (ข้อมูลการสมัคร, ประวัติสินเชื่อ, ข้อมูลเครดิตบูโร)

- **Data cleaning / Preprocessing**

- เนื่องจากเป็น "Clean Data" จะเน้นการตรวจสอบขั้นสุดท้าย การจัดการกับค่าที่หายไป (Missing Values) ที่ยังอาจมีอยู่

- **Target Variables & Feature**

- **Target Variable:**

- สถานะการอนุมัติ (Approved: '1', Rejected: '0')

- **Features:**

- คุณลักษณะของผู้สมัคร เช่น อายุ, รายได้, หนี้สิน, สถานภาพ, ประวัติเครดิต, ประเภทงาน (ตามคุณลักษณะใน Dataset)

- **Encoding & Scaling strategies**

- Encoding: ข้อมูลที่ไม่ใช่ตัวเลข (Non-numerical/Categorical Data) ให้กลายเป็นตัวเลข โดยใช้เทคนิคที่เรียกว่า Label Encoding

- Scaling: Standard Scaler สำหรับตัวแปรตัวเลข (Numerical)





## 4. Data Sources/Attributes

### Credit Card Approvals - Clean version of UCI dataset (Raw Data)

Gender	Age	Debt	Married	BankCustomer	Industry	Ethnicity	YearsEmployed	PriorDefault	Employed	CreditScore	DriversLicense	Citizen	ZipCode	Income	Approved
1	30.83	0	1	1	Industrials	White	1.25	1	1	1	0	ByBirth	202	0	1
0	58.67	4.46	1	1	Materials	Black	3.04	1	1	6	0	ByBirth	43	560	1
0	24.5	0.5	1	1	Materials	Black	1.5	1	0	0	0	ByBirth	280	824	1
1	27.83	1.54	1	1	Industrials	White	3.75	1	1	5	1	ByBirth	100	3	1
1	20.17	5.625	1	1	Industrials	White	1.71	1	0	0	0	ByOtherMeans	120	0	1
1	32.08	4	1	1	CommunicationServices	White	2.5	1	0	0	1	ByBirth	360	0	1
1	33.17	1.04	1	1	Transport	Black	6.5	1	0	0	1	ByBirth	164	31285	1
0	22.92	11.585	1	1	InformationTechnology	White	0.04	1	0	0	0	ByBirth	80	1349	1
1	54.42	0.5	0	0	Financials	Black	3.96	1	0	0	0	ByBirth	180	314	1
1	42.5	4.915	0	0	Industrials	White	3.165	1	0	0	1	ByBirth	52	1442	1
1	22.08	0.83	1	1	Energy	Black	2.165	0	0	0	1	ByBirth	128	0	1
1	29.92	1.835	1	1	Energy	Black	4.335	1	0	0	0	ByBirth	260	200	1
0	38.25	6	1	1	Financials	White	1	1	0	0	1	ByBirth	0	0	1
1	48.08	6.04	1	1	Financials	White	0.04	0	0	0	0	ByBirth	0	2690	1
0	45.83	10.5	1	1	Materials	White	5	1	1	7	1	ByBirth	0	0	1
1	36.67	4.415	0	0	Financials	White	0.25	1	1	10	1	ByBirth	320	0	1
1	28.25	0.875	1	1	CommunicationServices	White	0.96	1	1	3	1	ByBirth	396	0	1
0	23.25	5.875	1	1	Materials	White	3.17	1	1	10	0	ByBirth	120	245	1
1	21.83	0.25	1	1	Real Estate	Black	0.665	1	0	0	1	ByBirth	0	0	1

#### Credit Card Approvals - Clean version of UCI dataset

Data Source: <https://www.kaggle.com/datasets/samuelcortinhas/credit-card-approval-clean-data/>

Missing values have been filled and feature names and categorical names have been inferred, resulting in more context and it being easier to use. Your task is to predict which people in the dataset are successful in applying for a credit card.



## 4. Data Sources/Attributes

### Cleansing Data

- Cleaning Data with Power Query

- เนื่องจากเป็นข้อมูลที่ได้มาเป็น "Clean Data" จะเน้นการตรวจสอบขั้นสุดท้าย การจัดการกับค่าที่หายไป (Missing Values) ที่ยังอาจมีอยู่ / Data Type ที่เหมาะสม รวมถึงการเพิ่ม Field เป็นต้น

fx

= Table.TransformColumnTypes(Source,{{"Gender", Int64.Type}, {"Age", type number}, {"Debt", type number}, {"Married", Int64.Type}, {"BankCustomer", Int64.Type}, {"Industry", type text},

	1.3 Gender	1.2 Age	1.2 Debt	1.3 Married	1.3 BankCustomer	A <sup>B</sup> Industry	A <sup>B</sup> Ethnicity	1.2 YearsEmployed	1.3 PriorDefault
	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>2 distinct, 0 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>350 distinct, 170 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>215 distinct, 106 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>2 distinct, 0 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>2 distinct, 0 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>14 distinct, 0 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>5 distinct, 0 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>132 distinct, 56 unique</div>	<div> <div>Valid 100%</div> <div>Error 0%</div> <div>Empty 0%</div> </div> <div>2 distinct, 0 unique</div>
1	1	30.83	0	1	1	1 Industrials	White	1.25	
2	0	58.67	4.46	1	1	1 Materials	Black	3.04	
3	0	24.5	0.5	1	1	1 Materials	Black	1.5	
4	1	27.83	1.54	1	1	1 Industrials	White	3.75	
5	1	20.17	5.625	1	1	1 Industrials	White	1.71	
6	1	32.08	4	1	1	1 CommunicationServices	White	2.5	
7	1	33.17	1.04	1	1	1 Transport	Black	6.5	
8	0	22.92	11.585	1	1	1 InformationTechnology	White	0.04	
9	1	54.42	0.5	0	0	0 Financials	Black	3.96	
10	1	42.5	4.915	0	0	0 Industrials	White	3.165	
11	1	22.08	0.83	1	1	1 Energy	Black	2.165	
12	1	29.92	1.835	1	1	1 Energy	Black	4.335	
13	0	38.25	6	1	1	1 Financials	White	1	
14	1	48.08	6.04	1	1	1 Financials	White	0.04	
15	0	45.83	10.5	1	1	1 Materials	White	5	
16	1	36.67	4.415	0	0	0 Financials	White	0.25	
17	1	28.25	0.875	1	1	1 CommunicationServices	White	0.96	
18	0	23.25	5.875	1	1	1 Materials	White	3.17	
19	1	21.83	0.25	1	1	1 Real Estate	Black	0.665	
20	0	19.17	8.585	1	1	1 InformationTechnology	Black	0.75	



## 4. Data Sources/Attributes

### Cleaned Data

- Cleaning Data with Power Query

- เนื่องจากเป็นข้อมูลที่ได้มาเป็น "Clean Data" จะเน้นการตรวจสอบขั้นสุดท้าย การจัดการกับค่าที่หายไป (Missing Values) ที่ยังอาจมีอยู่ / Data Type ที่เหมาะสม รวมถึงการเพิ่ม Field เป็นต้น

Gender	Age	Debt	Married	BankCustomer	Industry	Industry_Name	Ethnicity	YearsEmployed	PriorDefault	Employed	CreditScore	DriversLicense	Citizen	ZipCode	StateName	Income	Approved
1	30.83	0.00	1	1	1	1 Industrials	White	1.25	1	1	1.00	0	ByBirth	00202 District of Columbia		0.00	1
1	27.83	1.54	1	1	1	1 Industrials	White	3.75	1	1	5.00	1	ByBirth	00100 Michigan		3.00	1
0	15.83	0.59	1	1	1	7 Energy	Black	1.50	1	1	2.00	0	ByBirth	00100 Michigan		0.00	1
1	23.92	0.67	1	1	1	7 Energy	White	0.17	0	0	0.00	0	ByBirth	00100 Michigan		0.00	1
0	49.00	1.50	1	1	1	14 Research	Other	0.00	1	0	0.00	1	ByBirth	00100 Michigan		27.00	0
1	22.75	11.00	1	1	1	2 Materials	White	2.50	1	1	7.00	1	ByBirth	00100 Michigan		809.00	1
1	20.42	1.84	1	1	1	7 Energy	White	2.25	1	1	1.00	0	ByBirth	00100 Michigan		150.00	1
1	43.00	0.29	0	0	0	5 InformationTechnology	Black	1.75	1	1	8.00	0	ByBirth	00100 Michigan		375.00	1
0	58.67	4.46	1	1	1	2 Materials	Black	3.04	1	1	6.00	0	ByBirth	00043 Ohio		560.00	1
1	20.17	5.63	1	1	1	1 Industrials	White	1.71	1	0	0.00	0	ByOtherMeans	00120 Indiana		0.00	1
0	23.25	5.88	1	1	1	2 Materials	White	3.17	1	1	10.00	0	ByBirth	00120 Indiana		245.00	1
0	27.42	14.50	1	1	1	9 Utilities	Black	3.09	1	1	1.00	0	ByBirth	00120 Indiana		11.00	1
1	26.67	4.25	1	1	1	5 InformationTechnology	White	4.29	1	1	1.00	1	ByBirth	00120 Indiana		0.00	1
1	31.42	15.50	1	1	1	7 Energy	White	0.50	1	0	0.00	0	ByBirth	00120 Indiana		0.00	0
1	25.00	12.00	1	1	1	6 Financials	White	2.25	1	1	2.00	1	ByBirth	00120 Indiana		5.00	0
0	25.00	11.00	0	0	0	12 ConsumerStaples	White	4.50	1	0	0.00	0	ByBirth	00120 Indiana		0.00	0
0	24.75	12.50	1	1	1	12 ConsumerStaples	White	1.50	1	1	12.00	1	ByBirth	00120 Indiana		567.00	1
0	23.50	9.00	1	1	1	2 Materials	White	8.50	1	1	5.00	1	ByBirth	00120 Indiana		0.00	1
0	24.50	0.50	1	1	1	2 Materials	Black	1.50	1	0	0.00	0	ByBirth	00280 North Carolina		824.00	1

18 Attributes / 690 Samples



## 4. Data Sources/Attributes

### Data Dictionary

Attribute	Description	Data Type	Valid Range/Example
Gender	Gender	Nominal	0=Female, 1=Male
Age	Age (Years)	Interval	[20, 80]
Debt	Outstanding debt (Feature has been scaled)	Ratio (Continuous)	[0, Infinity)
Married	Married Status	Nominal	Married, 0=Single/Divorced/etc, 1=Married
BankCustomer	Bank Customer Status	Nominal	0=Does not have a bank account, 1=Has a bank account)
Industry	Industry (Job sector of current or most recent job)	Nominal	[0, 14]
			[CommunicationServices, ConsumerDiscretionary, ConsumerStaples, Education, Energy, Financials, Healthcare, Industrials, InformationTechnology, Materials, Real Estate, Research, Transport, Utilities]
Industry_Name	Industry Name	Nominal	
Ethnicity	Ethnicity	Nominal	White, Black, Asian, Latino, Other
YearsEmployed	Years employed	Ratio (Discrete)	[0, Infinity)
PriorDefault	Prior default	Asymmetric Binary	0=No prior defaults, 1=Prior default
Employed	Employed Status	Asymmetric Binary	0=Not employed, 1=Employed
CreditScore	Credit score (Feature has been scaled)	Interval	[0, 100]
DriversLicense	Drivers license	Symmetric Binary	0=No license, 1=Has license
Citizen	Citizenship	Nominal	ByBirth, ByOtherMeans, Temporary
ZipCode	ZipCode	Nominal	5 digit number
StateName	StateName	Nominal	[100 = Michigan, etc.]
Income	Income (Feature has been scaled)	Ratio (Continuous)	[0, Infinity)
Approved	Approved Status	Asymmetric Binary	0=Not approved, 1=Approved



## 5. Analysis/Model Development

### Analytics Methodology

- **Exploratory Data Analysis - EDA techniques:** การวิเคราะห์ข้อมูลเบื้องต้น เช่น การวิเคราะห์ความถี่และค่าสถิติเชิงพรรณนา (Descriptive Statistics) เพื่อดูความสัมพันธ์ของแต่ละคุณลักษณะกับผลการอนุมัติ การหาความสัมพันธ์ระหว่างตัวแปร (Correlation)
- **Visualization strategy:** Heatmap สำหรับ Correlation Matrix
- **Segmentation approach:** การจัดกลุ่มลูกค้าตามโปรไฟล์ความเสี่ยง (Risk Profiles)



## 5. Analysis/Model Development

### Analytics Methodology

- **EDA techniques:** การวิเคราะห์ความถี่และค่าสถิติเชิงพรรณนา เพื่อดูความสัมพันธ์ของแต่ละคุณลักษณะกับผลการอนุมัติ

	Gender	Age	Debt	Married	BankCustomer	Industry	YearsEmployed	PriorDefault	Employed	CreditScore	DriversLicense	ZipCode	Income	Approved
count	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000	690.000000
mean	0.695652	31.514116	4.758725	0.760870	0.763768	6.960870	2.223406	0.523188	0.427536	2.400000	0.457971	180.547826	1017.385507	0.444928
std	0.460464	11.860245	4.978163	0.426862	0.425074	3.802822	3.346513	0.499824	0.495080	4.86294	0.498592	173.970323	5210.102598	0.497318
min	0.000000	13.750000	0.000000	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.000000	22.670000	1.000000	1.000000	1.000000	3.000000	0.165000	0.000000	0.000000	0.000000	0.000000	60.000000	0.000000	0.000000
50%	1.000000	28.460000	2.750000	1.000000	1.000000	7.000000	1.000000	1.000000	0.000000	0.000000	0.000000	160.000000	5.000000	0.000000
75%	1.000000	37.707500	7.207500	1.000000	1.000000	10.000000	2.625000	1.000000	1.000000	3.000000	1.000000	272.000000	395.500000	1.000000
max	1.000000	80.250000	28.000000	1.000000	1.000000	14.000000	28.500000	1.000000	1.000000	67.000000	1.000000	2000.000000	100000.000000	1.000000

สถิติเชิงพรรณนา (Descriptive Statistics)



## 5. Analysis/Model Development

### สถิติเชิงพรรณนา (Descriptive Statistics)

Income		Debt		CreditScore		Age	
Mean	1,017.39	Mean	4.76	Mean	2.40	Mean	31.51
Standard Error	198.35	Standard Error	0.19	Standard Error	0.19	Standard Error	0.45
Median	5.00	Median	2.75	Median	-	Median	28.46
Mode	-	Mode	1.50	Mode	-	Mode	28.46
Standard Deviation	5,210.10	Standard Deviation	4.98	Standard Deviation	4.86	Standard Deviation	11.86
Sample Variance	27,145,169.08	Sample Variance	24.78	Sample Variance	23.65	Sample Variance	140.67
Kurtosis	214.67	Kurtosis	2.27	Kurtosis	50.83	Kurtosis	1.20
Skewness	13.14	Skewness	1.49	Skewness	5.15	Skewness	1.17
Range	100,000.00	Range	28.00	Range	67.00	Range	66.50
Minimum	-	Minimum	-	Minimum	-	Minimum	13.75
Maximum	100,000.00	Maximum	28.00	Maximum	67.00	Maximum	80.25
Sum	701,996.00	Sum	3,283.52	Sum	1,656.00	Sum	21,744.74
Count	690.00	Count	690.00	Count	690.00	Count	690.00

### Statistic Description

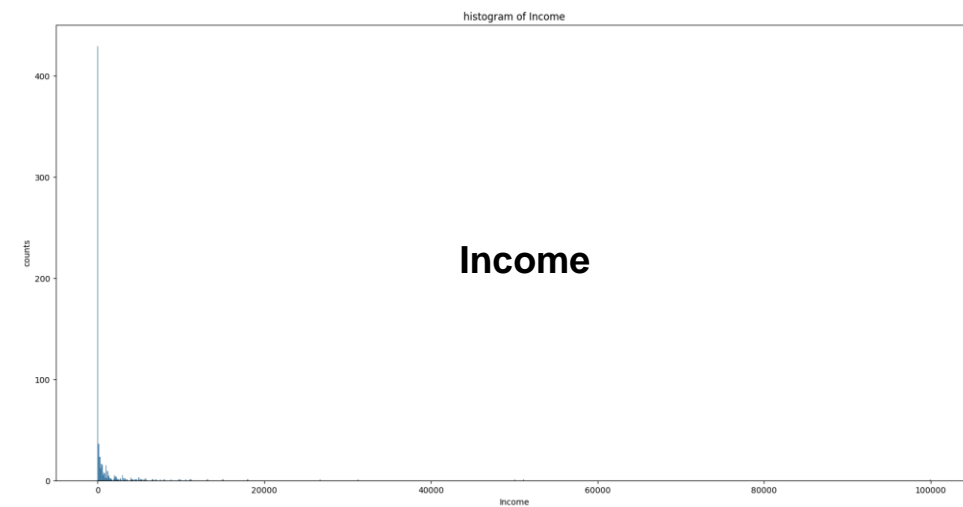



**Income** ชุดข้อมูลประกอบด้วยข้อมูลสังเกตทั้งหมด 690 รายการ ค่ารายได้มีช่วงตั้งแต่ต่ำสุด 0 K ถึงสูงสุด 100,000 K โดยมีช่วงทั้งหมด (Range) 100,000 ผลรวมรายได้ทั้งหมดคือ 701,996 ข้อมูลมีความเบ้สูง รายได้เฉลี่ยอยู่ที่ประมาณ 1,017 K ขณะที่ค่ามัธยฐาน (Median) อยู่ที่เพียง 5 และค่าฐานนิยม (Mode) อยู่ที่ 0 ความแตกต่างที่มากระหว่างค่าเฉลี่ย ค่ามัธยฐาน และค่าฐานนิยมนี้บ่งชี้ว่าข้อมูลมีความเบ้ไปทางขวาอย่างมาก ซึ่งหมายความว่าค่ารายได้สูงมากบางค่าดึงค่าเฉลี่ยขึ้นอย่างมีนัยสำคัญ ปัจจัยนี้ยังได้รับการสนับสนุนจากค่าเบ้ (Skewness) ที่สูงมากถึง 13.14 และค่าความโด่ง (Kurtosis) ที่สูงถึง 214.67 ซึ่งแสดงถึงค่าผิดปกติจำนวนมากและการกระจายตัวที่จุดสูงสุด ค่าเบี่ยงเบนมาตรฐาน (SD) ที่ 5,210.10 ค่อนข้างสูง ซึ่งยืนยันการกระจายตัวที่กว้างของข้อมูลและการมีอยู่ของค่าผิดปกติที่มีนัยสำคัญ

**CreditScore** ชุดข้อมูลประกอบด้วยข้อมูลการสังเกต 690 รายการ คะแนนเครดิตมีช่วงตั้งแต่ต่ำสุด 0 ถึงสูงสุด 67 โดยมีช่วงคะแนนรวม 67 คะแนน ผลรวมของคะแนนเครดิตทั้งหมดคือ 1,656 ข้อมูลมีความเบ้สูง คะแนนเครดิตเฉลี่ยอยู่ที่ 2.4 ขณะที่ค่ามัธยฐานและค่าฐานนิยมอยู่ที่ 0 ทั้งคู่ ความแตกต่างที่สำคัญนี้ชี้ให้เห็นว่าข้อมูลการสังเกตจำนวนมากอยู่ที่หรือใกล้ศูนย์ และมีค่าสูงบางค่าที่ทำให้ค่าเฉลี่ยสูงขึ้น ค่าความเบ้ที่สูงถึง 5.15 ยืนยันว่าการเบ้ไปทางขวาอย่างชัดเจน ค่าเบี่ยงเบนมาตรฐานอยู่ที่ 4.86 ซึ่งบ่งชี้ถึงการกระจายตัวของข้อมูลอย่างกว้างขวาง ค่าความโด่งที่สูงมากถึง 50.83 บ่งชี้ถึงการกระจายตัวที่มีจุดสูงสุดและหางที่มาก ซึ่งอาจเป็นผลมาจากค่าจำนวนมาก ณ จุดหนึ่ง (ศูนย์) และค่าผิดปกติที่มีนัยสำคัญบางประการ



## 5. Analysis/Model Development

### Graph – Visualization – Pivot Table








## 5. Analysis/Model Development

Graph – Visualization – Pivot Table

Industry Name	Number of Approved
CommunicationServices	16
ConsumerDiscretionary	14
ConsumerStaples	19
Education	14
Energy	66
Financials	14
Healthcare	7
Industrials	33
InformationTechnology	29
Materials	51
Real Estate	7
Research	3
Transport	2
Utilities	32
Grand Total	307






## 5. Analysis/Model Development

### Graph – Visualization – Pivot Table

Approval Distribution by Ethnicity



Approval Distribution by Bank Account Status





## 5. Analysis/Model Development

### Pearson Correlation (สัมประสิทธิ์สหสัมพันธ์แบบเพียร์สัน)

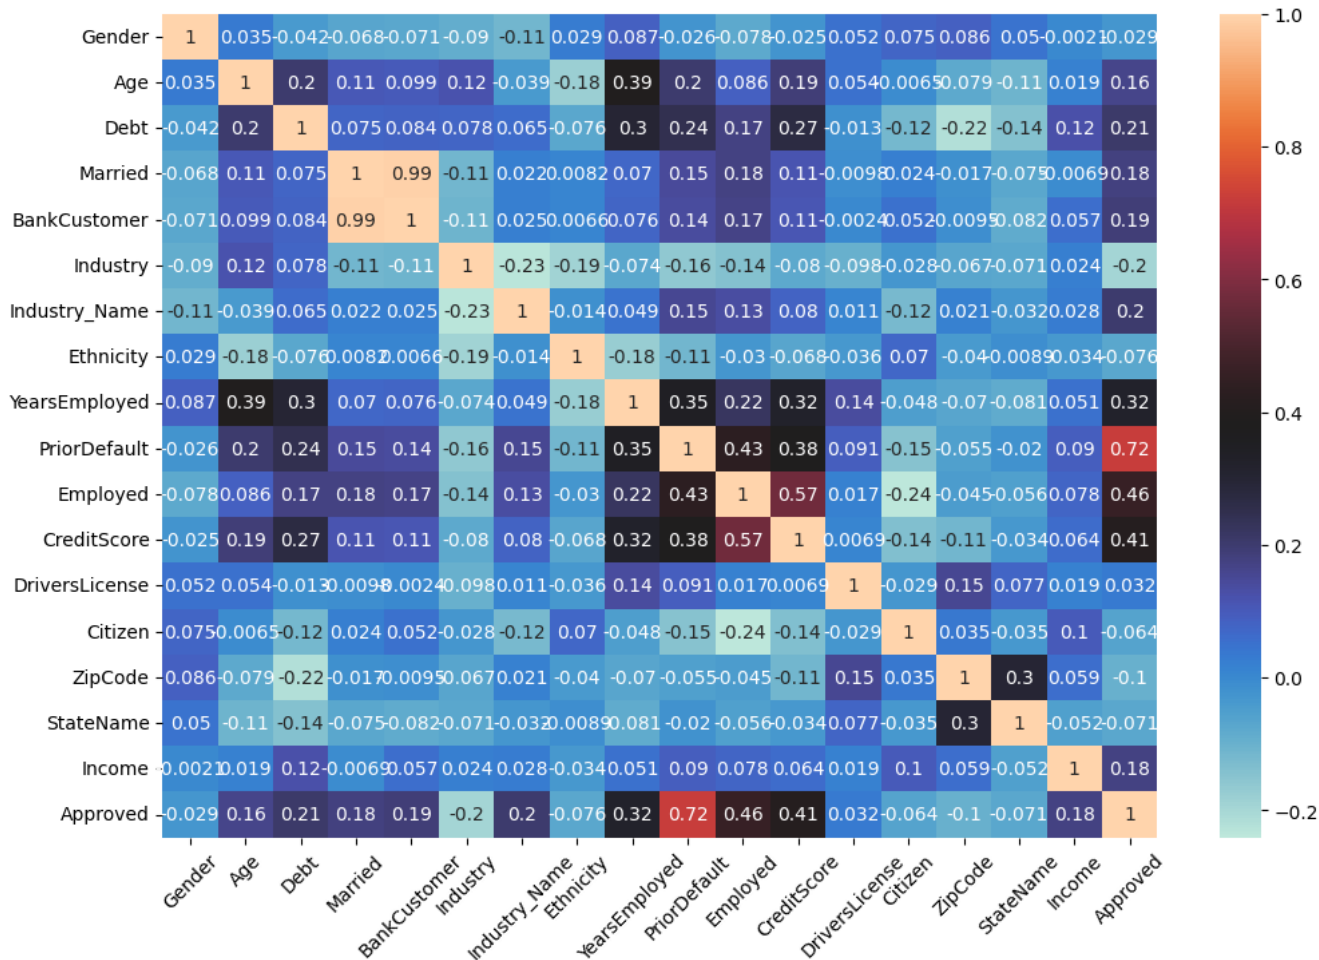
- Pearson correlation (สัมประสิทธิ์สหสัมพันธ์แบบเพียร์สัน) คือ ค่าที่ใช้วัดความสัมพันธ์เชิงเส้น (Linear Relationship) ระหว่างตัวแปรเชิงปริมาณ (Quantitative Variables) สองตัว มีค่าดังตาราง

	Gender	Age	Debt	Married	BankCustomer	Industry	Industry_Name	Ethnicity	YearsEmployed	PriorDefault	Employed	CreditScore	DriversLicense	Citizen	ZipCode	StateName	Income	Approved
Gender	1.000000	0.035044	-0.041746	-0.068062	-0.071250	-0.089697	-0.111889	0.029492	0.086544	-0.026047	-0.077784	-0.024630	0.051674	0.075413	0.086007	0.049724	-0.002063	-0.028934
Age	0.035044	1.000000	0.202177	0.106929	0.099477	0.120104	-0.038746	-0.179534	0.391464	0.204434	0.086037	0.187327	0.053599	-0.006481	-0.078690	-0.107888	0.018719	0.164086
Debt	-0.041746	0.202177	1.000000	0.074649	0.083781	0.078030	0.064553	-0.075789	0.298902	0.244317	0.174846	0.271207	-0.013023	-0.116975	-0.217903	-0.141502	0.123121	0.206294
Married	-0.068062	0.106929	0.074649	1.000000	0.992033	-0.111277	0.021652	0.008226	0.069945	0.145073	0.175428	0.113968	-0.009784	0.024319	-0.017074	-0.075021	-0.006899	0.180583
BankCustomer	-0.071250	0.099477	0.083781	0.992033	1.000000	-0.108083	0.024677	0.006648	0.075905	0.138535	0.170268	0.111077	-0.002402	0.052141	-0.009513	-0.082177	0.057273	0.188964
Industry	-0.089697	0.120104	0.078030	-0.111277	-0.108083	1.000000	-0.232826	-0.190879	-0.074235	-0.161784	-0.143740	-0.079754	-0.097701	-0.027940	-0.067478	-0.071252	0.023707	-0.196453
Industry_Name	-0.111889	-0.038746	0.064553	0.021652	0.024677	-0.232826	1.000000	-0.013881	0.048689	0.154645	0.134769	0.080107	0.011010	-0.122211	0.020551	-0.032218	0.027820	0.202158
Ethnicity	0.029492	-0.179534	-0.075789	0.008226	0.006648	-0.190879	-0.013881	1.000000	-0.177111	-0.114148	-0.030250	-0.068072	-0.035688	0.070235	-0.040003	-0.008858	-0.034251	-0.075558
YearsEmployed	0.086544	0.391464	0.298902	0.069945	0.075905	-0.074235	0.048689	-0.177111	1.000000	0.345689	0.222982	0.322330	0.138139	-0.047522	-0.070495	-0.080999	0.051345	0.322475
PriorDefault	-0.026047	0.204434	0.244317	0.145073	0.138535	-0.161784	0.154645	-0.114148	0.345689	1.000000	0.432032	0.379532	0.091276	-0.145357	-0.055010	-0.020499	0.090012	0.720407
Employed	-0.077784	0.086037	0.174846	0.175428	0.170268	-0.143740	0.134769	-0.030250	0.222982	0.432032	1.000000	0.571498	0.017043	-0.240789	-0.044834	-0.055918	0.077652	0.458301
CreditScore	-0.024630	0.187327	0.271207	0.113968	0.111077	-0.079754	0.080107	-0.068072	0.322330	0.379532	0.571498	1.000000	0.006944	-0.138341	-0.112816	-0.033683	0.063692	0.406410
DriversLicense	0.051674	0.053599	-0.013023	-0.009784	-0.002402	-0.097701	0.011010	-0.035688	0.138139	0.091276	0.017043	0.006944	1.000000	-0.029087	0.154924	0.077415	0.019201	0.031625
Citizen	0.075413	-0.006481	-0.116975	0.024319	0.052141	-0.027940	-0.122211	0.070235	-0.047522	-0.145357	-0.240789	-0.138341	-0.029087	1.000000	0.035488	-0.035296	0.102000	-0.063556
ZipCode	0.086007	-0.078690	-0.217903	-0.017074	-0.009513	-0.067478	0.020551	-0.040003	-0.070495	-0.055010	-0.044834	-0.112816	0.154924	0.035488	1.000000	0.301966	0.059234	-0.099598
StateName	0.049724	-0.107888	-0.141502	-0.075021	-0.082177	-0.071252	-0.032218	-0.008858	-0.080999	-0.020499	-0.055918	-0.033683	0.077415	-0.035296	0.301966	1.000000	-0.052210	-0.071361
Income	-0.002063	0.018719	0.123121	-0.006899	0.057273	0.023707	0.027820	-0.034251	0.051345	0.090012	0.077652	0.063692	0.019201	0.102000	0.059234	-0.052210	1.000000	0.175657
Approved	-0.028934	0.164086	0.206294	0.180583	0.188964	-0.196453	0.202158	-0.075558	0.322475	0.720407	0.458301	0.406410	0.031625	-0.063556	-0.099598	-0.071361	0.175657	1.000000



## 5. Analysis/Model Development

### Correlation Heatmap (แผนที่ความร้อนสหสัมพันธ์)



ค่าสัมประสิทธิ์สหสัมพันธ์แบบเพียร์สัน (Pearson Correlation) ที่มีค่ามากกว่า 0.3 (ทั้งค่าบวกและลบ) หมายความว่ามีความสัมพันธ์เชิงเส้นระหว่างตัวแปรทั้งสองในระดับ ปานกลางถึงค่อนข้างมาก โดยมีค่าดังนี้

Married and BankCustomer = 0.992

PriorDefault and Approved = 0.720

Employed and CreditScore = 0.571

Employed and Approved = 0.458

PriorDefault and Employed = 0.432

CreditScore and Approved = 0.406

Age and YearsEmployed = 0.391

PriorDefault and CreditScore = 0.380

YearsEmployed and PriorDefault = 0.346

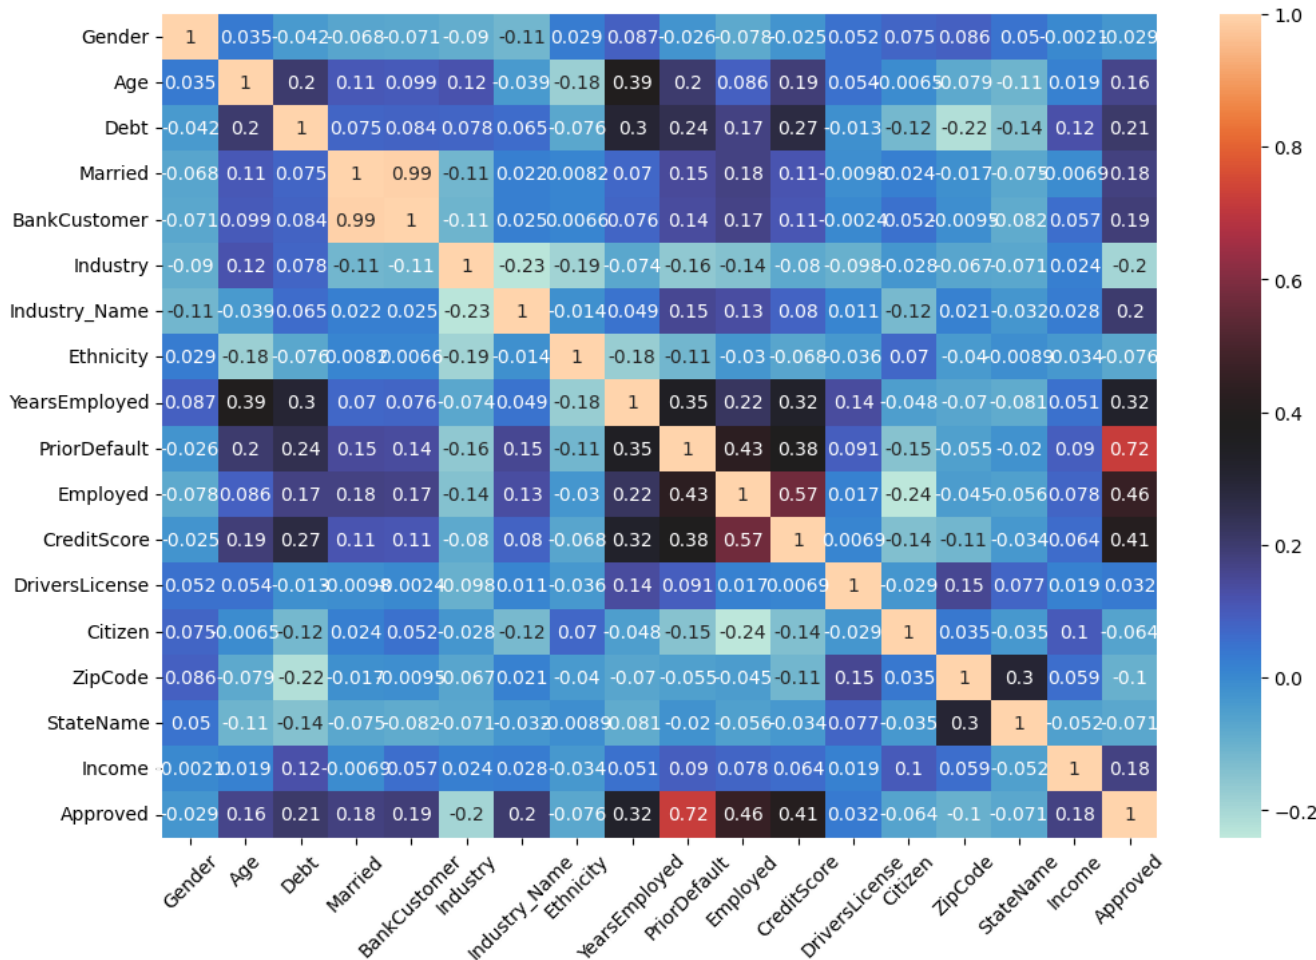
YearsEmployed and CreditScore = 0.322

ZipCode and StateName = 0.302



## 5. Analysis/Model Development

### Correlation Heatmap (แผนที่ความร้อนสหสัมพันธ์)



ค่าสัมประสิทธิ์สหสัมพันธ์แบบเพียร์สัน (Pearson Correlation) ที่มีค่ามากกว่า 0.3 (ทั้งค่าบวกและลบ) หมายความว่ามีความสัมพันธ์เชิงเส้นระหว่างตัวแปรทั้งสองในระดับ ปานกลางถึงค่อนข้างมาก โดยมีค่าดังนี้

Married and BankCustomer = 0.992

PriorDefault and Approved = 0.720

Employed and CreditScore = 0.571

Employed and Approved = 0.458

PriorDefault and Employed = 0.432

CreditScore and Approved = 0.406

Age and YearsEmployed = 0.391

PriorDefault and CreditScore = 0.380

YearsEmployed and PriorDefault = 0.346

YearsEmployed and Approved = 0.322

YearsEmployed and CreditScore = 0.322

ZipCode and StateName = 0.302



## 5. Analysis/Model Development

### การวิเคราะห์ข้อมูลเบื้องต้น (Analytical Insights)

ผลจากการวิเคราะห์ความสัมพันธ์ของฟีเจอร์ (Correlation Analysis) เป็นไปตามสมมติฐานที่ว่าคุณลักษณะบางอย่างของผู้สมัครมีความสัมพันธ์อย่างมากกับผลการอนุมัติ

ความสัมพันธ์ที่โดดเด่น	ค่า Correlation	ความหมายเชิงธุรกิจ
PriorDefault and Approved	0.720	สำคัญที่สุด: ผู้สมัครที่มีประวัติ ไม่เคยผิดนัดชำระหนี้ (PriorDefault=0) มีโอกาสได้รับการอนุมัติสูงมาก (ความเสี่ยงต่ำ)
Employed and Approved	0.458	ผู้สมัครที่มี งานทำ (Employed=1) มีแนวโน้มได้รับการอนุมัติสูงกว่า
CreditScore and Approved	0.406	คะแนนเครดิตสูง เป็นปัจจัยหลักในการอนุมัติ
YearsEmployed and Approved	0.322	ระยะเวลาการทำงานที่ยาวนาน มีความสัมพันธ์กับการอนุมัติ ซึ่งบ่งชี้ถึง ความมั่นคงทางการเงิน

บทสรุปเชิงวิเคราะห์: ปัจจัยด้าน ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผลการตัดสินใจอนุมัติบัตรเครดิต ซึ่งตอบคำถามเชิงวิเคราะห์ที่ว่า "คุณลักษณะใดของผู้สมัครมีความสัมพันธ์กับการอนุมัติมากที่สุด"



## 5. Analysis/Model Development

### การวิเคราะห์ข้อมูลเบื้องต้น (Analytical Insights)

การเปรียบเทียบ **Credit Score (CreditScore)** ระหว่างผู้ที่ได้รับการอนุมัติ (Approved=1) และผู้ที่ไม่ได้รับการอนุมัติ (Approved=0) สามารถทำ **t-test** ได้ เนื่องจาก CreditScore เป็นตัวแปรเชิงปริมาณ (Numerical/Continuous) และเราต้องการเปรียบเทียบค่าเฉลี่ยของตัวแปรนี้ระหว่างสองกลุ่มอิสระ (Approved=1 และ Approved=0) การใช้ **Independent Samples T-test** (การทดสอบทีสำหรับกลุ่มตัวอย่างอิสระ) จึงเป็นวิธีที่เหมาะสมที่สุด

#### Independent Samples T-test

สมมติฐาน

$H_0$  (สมมติฐานว่าง): ค่าเฉลี่ย CreditScore ของผู้ที่ได้รับการอนุมัติ **ไม่แตกต่าง** จากผู้ที่ไม่ได้รับการอนุมัติ

$H_a$  (สมมติฐานทางเลือก): ค่าเฉลี่ย CreditScore ของผู้ที่ได้รับการอนุมัติ **แตกต่าง** จากผู้ที่ไม่ได้รับการอนุมัติ

ค่าเฉลี่ย CreditScore กลุ่ม Approved (1): 4.6059 (307 Samples)

ค่าเฉลี่ย CreditScore กลุ่ม Not Approved (0): 0.6319 (383 Samples)

ค่า T-statistic: 10.6384

ค่า T ที่สูงมากนี้บ่งชี้ว่ามีความแตกต่างระหว่างค่าเฉลี่ยของทั้งสองกลุ่มค่อนข้างมากเมื่อเทียบกับความผันแปรภายในกลุ่ม

ค่า P-value: 0.0000

**P-value < 0.05: ปฏิเสธ  $H_0$  สรุปได้ว่า Credit Score เฉลี่ยแตกต่างกันอย่างมีนัยสำคัญ**

ผลจากการวิเคราะห์ความสัมพันธ์ของพีเจอร์ (Correlation Analysis) เป็นไปตามสมมติฐานที่ว่า มีกลุ่มลูกค้า (Segments) ที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันชัดเจนหรือไม่? -- สรุป ค่าเฉลี่ย Credit Score ของผู้ที่ได้รับการอนุมัติ **แตกต่าง** จากผู้ที่ไม่ได้รับการอนุมัติ





## 5. Analysis/Model Development

### บทสรุปเชิงกลยุทธ์: ความเสี่ยงและประสิทธิภาพของ Credit Score

จากผลการวิเคราะห์ T-test พบว่า Credit Score เป็นตัวแปรที่มีพลังในการจำแนกสูงมากระหว่างกลุ่มลูกค้าที่ได้รับการอนุมัติและไม่ได้รับการอนุมัติ ข้อมูลนี้ชี้ให้เห็นถึงกลไกการตัดสินใจที่เข้มแข็ง (Strong Decision Mechanism) แต่ก็เผยให้เห็นข้อจำกัดที่ควรนำไปสู่การปรับปรุงเชิงกลยุทธ์

#### 1. สมมติฐานการแบ่งกลุ่มลูกค้าตามความเสี่ยง (Customer Segmentation)

คำตอบ: มีกลุ่มลูกค้าที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันอย่างชัดเจน

**กลุ่มความเสี่ยงต่ำ (Low-Risk/Approved Group):** ลูกค้าที่ได้รับการอนุมัติมี Credit Score เฉลี่ยสูงถึง 4.61 สะท้อนให้เห็นว่ากลุ่มนี้มีประวัติทางการเงินที่ดีและตรงตามเกณฑ์หลักของธนาคารอย่างชัดเจน

**กลุ่มความเสี่ยงสูง (High-Risk/Not Approved Group):** ลูกค้าที่ไม่ได้รับการอนุมัติมี Credit Score เฉลี่ยต่ำมากถึง 0.63 แสดงให้เห็นว่ากลุ่มนี้มีโปรไฟล์ความเสี่ยงสูงมากและถูกปฏิเสธอย่างชัดเจน

**ข้อสรุปเชิงธุรกิจ:** ปัจจุบัน Credit Score เป็นปัจจัยขับเคลื่อนหลัก (Primary Driver) ในกระบวนการอนุมัติ ทำให้เกิดการแบ่งกลุ่มลูกค้าเป็นสองขั้วอย่างมีประสิทธิภาพ





## 5. Analysis/Model Development

บทสรุปเชิงกลยุทธ์: ความเสี่ยงและประสิทธิภาพของ Credit Score

### 2. ข้อบกพร่องในเกณฑ์การตัดสินใจแบบเดิม

คำตอบ: หากเกณฑ์การตัดสินใจพึ่งพา CreditScore เพียงอย่างเดียวหรือใช้ค่า Cutoff ที่ไม่ยืดหยุ่น อาจเกิดข้อบกพร่องดังต่อไปนี้

ข้อบกพร่องที่อาจเกิดขึ้น	นัยยะทางธุรกิจ
การพึ่งพาตัวแปรเดียวมากเกินไป (Over-reliance on CreditScore)	อาจจะละเลยศักยภาพของลูกค้าที่มี CreditScore ปานกลาง (Gray Zone) แต่มีปัจจัยชดเชยอื่น ๆ ที่แข็งแกร่ง (เช่น Income สูงมาก หรือ YearsEmployed ยาวนาน) ซึ่งอาจกลายเป็นลูกค้าที่ดีในอนาคต
การใช้ค่า Cutoff แบบแข็งตัว	การใช้ค่า Cutoff แบบตายตัวอาจทำให้เสียโอกาส (Lost Opportunities) ในการอนุมัติลูกค้าที่เพิ่งผ่านเกณฑ์มาเพียงเล็กน้อย หรือปฏิเสธลูกค้าที่อยู่ต่ำกว่าเกณฑ์นิดเดียวแต่มีความเสี่ยงต่ำเมื่อรวมปัจจัยอื่น
การไม่พิจารณา Interaction Effects	เกณฑ์แบบเดิมอาจไม่ได้ให้ความสำคัญกับการทำงานร่วมกันของปัจจัย (เช่น ลูกค้าที่มี CreditScore ต่ำ แต่มีประวัติการจ้างงานมั่นคงยาวนาน) ทำให้การตัดสินใจขาดความแม่นยำในกลุ่มลูกค้าที่ซับซ้อน



## 5. Analysis/Model Development

### บทสรุปเชิงกลยุทธ์: ความเสี่ยงและประสิทธิภาพของ Credit Score

#### บทสรุปและการดำเนินการที่แนะนำ (Executive Summary & Recommendation)

Credit Score เป็นมาตรวัดที่มีประสิทธิภาพสูงและเป็นตัวชี้วัดความเสี่ยงที่เชื่อถือได้ ในกระบวนการอนุมัติสินเชื่อปัจจุบัน ซึ่งสะท้อนให้เห็นถึงการแบ่งกลุ่มลูกค้าที่มีความเสี่ยงต่ำและสูงอย่างชัดเจน อย่างไรก็ตาม เพื่อเพิ่มประสิทธิภาพในการอนุมัติและลดความเสี่ยงจากการพลาดโอกาสทางธุรกิจ (Opportunity Loss)

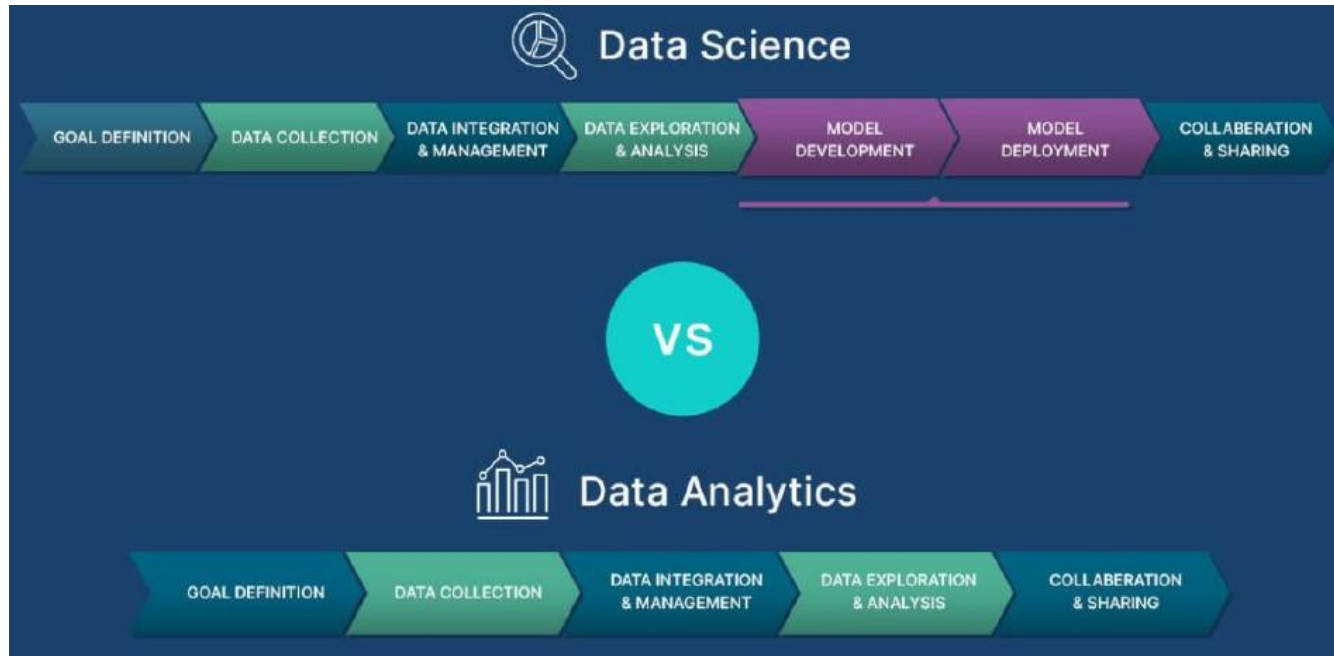
#### การดำเนินการที่แนะนำ:

1. วิเคราะห์ค่า Cutoff ใหม่: ทำการศึกษาเชิงลึกเพื่อหา CreditScore ค่า Cutoff ที่เหมาะสมที่สุด (Optimal Threshold) เพื่อให้แน่ใจว่าไม่ได้ปฏิเสธลูกค้าที่มีคุณสมบัติเพียงพอโดยไม่จำเป็น
2. สร้างแบบจำลองคะแนนรวม (Composite Scoring Model): พัฒนาระบบการให้คะแนนที่ผนวก CreditScore เข้ากับตัวแปรสำคัญอื่น ๆ เช่น Income YearsEmployed, และ Debt โดยมีการถ่วงน้ำหนัก (Weighted Score) เพื่อให้การตัดสินใจมีความแม่นยำและครอบคลุมกลุ่มลูกค้าในเขตสีเทา (Gray Zone) มากขึ้น
3. ทบทวนกลยุทธ์การอนุมัติ: ใช้ความแตกต่างของ CreditScore นี้เป็นหลักฐานในการปรับปรุงนโยบายสินเชื่อ โดยให้ความยืดหยุ่นมากขึ้นสำหรับลูกค้าที่อาจมี CreditScore ต่ำกว่าเกณฑ์เล็กน้อย แต่มีปัจจัยด้านอื่น ๆ ที่ชดเชยความเสี่ยงได้



## 5. Analysis/Model Development

### Modeling Methodology



### Model Development

- **Algorithm selection:** Classification Algorithms: Logistic Regression
- **Training, hyperparameter tuning, evaluation metric:**  
Training: แบ่งข้อมูลเป็น Training, Validation และ Test Sets (Cross-Validation) Tuning: Grid Search เพื่อหา Hyperparameters ที่เหมาะสมที่สุด
- **Evaluation Metric:** Accuracy, Precision, Recall, F1-Score



## 5. Analysis/Model Development

### Workflow– Model Development

```
▶ x = df1.drop('Approved', axis = 1)
  y = df1['Approved']
```

```
print(x.shape)
x.head()
```

(690, 17)

	Gender	Age	Debt	Married	BankCustomer	Industry	Industry_Name	Ethnicity	YearsEmployed	PriorDefault	Employed	CreditScore	DriversLicense	Citizen	ZipCode	StateName	Income
0	1	30.83	0.000	1	1	1	7	4	1.250	1	1	1	0	0	202	8	0
1	1	27.83	1.540	1	1	1	7	4	3.750	1	1	5	1	0	100	22	3
2	0	15.83	0.585	1	1	7	4	1	1.500	1	1	2	0	0	100	22	0
3	1	23.92	0.665	1	1	7	4	4	0.165	0	0	0	0	0	100	22	0
4	0	49.00	1.500	1	1	14	11	3	0.000	1	0	0	1	0	100	22	27

```
print(y.shape)
y.head()
```

(690,)

Approved

0	1
1	1
2	1
3	1
4	0

dtype: int64



## 5. Analysis/Model Development

### Workflow– Model Development

```
# train_test_split จากไลบรารี scikit-learn เพื่อแบ่งข้อมูลทั้งหมด (x คือฟีเจอร์, y คือตัวแปรเป้าหมาย) ออกเป็น 4 ส่วน สำหรับใช้ในกระบวนการฝึกฝนและประเมินผลโมเดลแมชชีนเลิร์นนิง

from sklearn.model_selection import train_test_split

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.25, random_state = 0)
```

```
# ทำให้ชุดข้อมูลการฝึก (x_train) และชุดข้อมูลการทดสอบ (x_test) มีมาตราส่วนเดียวกัน (Scale)

from sklearn.preprocessing import StandardScaler

sc = StandardScaler()
x_train = sc.fit_transform(x_train)
x_test = sc.transform(x_test)
```

```
# Build Machine Learning Model - Model name: Logistic Regression
from sklearn.linear_model import LogisticRegression

log_reg = LogisticRegression(random_state = 0)
log_reg.fit(x_train, y_train)
```

```
LogisticRegression
LogisticRegression(random_state=0)
```

```
y_pred = log_reg.predict(x_test)
print("Train Score: {:.5f}".format(log_reg.score(x_train, y_train)))
print("Test Score: {:.5f}".format(log_reg.score(x_test, y_test)))
```

```
Train Score: 0.87041
Test Score: 0.86705
```



## 5. Analysis/Model Development

### Workflow– Model Development (Parameter / Hyperparameter Tuning)

Parameter / Hyperparameter Tuning การค้นหาชุดของค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล

```
# โมเดล Logistic Regression กำหนดค่าพารามิเตอร์ C = 0.1 เป็นความผกผันของค่าความแรงของการปรับให้เป็นระเบียบ (Regularization)
# กำหนดประเภทของ Regularization เป็น L1 Regularization L1 Regularization มักเรียกว่า Lasso
# กำหนดอัลกอริทึมที่ใช้ในการหาค่าที่ดีที่สุด (Optimization Algorithm)
```

```
log_reg1 = LogisticRegression(C=0.1, penalty='l1', solver='liblinear', random_state = 0)
log_reg1.fit(x_train, y_train)
```

```
LogisticRegression
LogisticRegression(C=0.1, penalty='l1', random_state=0, solver='liblinear')
```

```
y_pred1 = log_reg1.predict(x_test)
print("Train Score: {:.5f}".format(log_reg1.score(x_train, y_train)))
print("Test Score: {:.5f}".format(log_reg1.score(x_test, y_test)))
```

```
Train Score: 0.85880
Test Score: 0.84971
```



## 5. Analysis/Model Development

### Workflow– Model Development (Parameter / Hyperparameter Tuning with GridsearchCV)

Parameter / Hyperparameter Tuning การค้นหาชุดของค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล

```
# กำหนดพารามิเตอร์
paragrid = { 'C': [0.0001, 0.001, 0.01, 0.1, 1, 10, 100, 1000], 'penalty':['l1', 'l2'], 'solver':['liblinear']}

from sklearn.model_selection import GridSearchCV
grid_search = GridSearchCV(LogisticRegression(), param_grid=paragrid, cv=5, scoring='accuracy')

grid_search.fit(x_train, y_train)

# ดูพารามิเตอร์ที่ดีที่สุด
print("Best Parameters:", grid_search.best_params_)
# คะแนนความแม่นยำ (Accuracy Score) เฉลี่ยสูงสุด ที่ได้จากการประเมินโมเดลในกระบวนการ Cross-Validation (CV)
print("Best Score:{:.5f}".format(grid_search.best_score_))

# คะแนนความแม่นยำ (Accuracy Score) ที่ได้จากการประเมินโมเดลสุดท้าย (โมเดลที่ดีที่สุดจากการทำ Grid Search) บนชุดข้อมูล x_train ทั้งหมด
print("Grid Search - Train Score: {:.5f}".format(grid_search.score(x_train, y_train)))
print("Grid Search - Test Score: {:.5f}".format(grid_search.score(x_test, y_test)))
```

```
Best Parameters: {'C': 10, 'penalty': 'l1', 'solver': 'liblinear'}
Best Score:0.87018
Grid Search - Train Score: 0.87621
Grid Search - Test Score: 0.87861
```



## 5. Analysis/Model Development

### Workflow– Model Development (Parameter / Hyperparameter Tuning with Pipeline and GridsearchCV)

Parameter / Hyperparameter Tuning การค้นหาชุดของค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล

```
import pandas as pd
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

# 1. กำหนดขั้นตอนใน Pipeline
# -----
# ใช้ StandardScaler และ LogisticRegression
steps = [
    ('scaler', StandardScaler()), # ขั้นตอนที่ 1: Data Preprocessing (Standardization)
    ('model', LogisticRegression(random_state=0)) # ขั้นตอนที่ 2: Model (Logistic Regression)
]

pipeline = Pipeline(steps)
# -----

# 2. กำหนด Hyperparameters สำหรับ Grid Search ในรูปแบบ Pipeline
# -----
# กำหนดค่าพารามิเตอร์ใน Pipeline
paragrid = {
    'model__C': [0.0001, 0.001, 0.01, 0.1, 1, 10, 100, 1000],
    'model__penalty': ['l1', 'l2'],
    'model__solver': ['liblinear']
}
# -----
```

# 3. สร้าง Grid Search และทำการฝึกฝน (Fit)

```
grid_search = GridSearchCV(
    pipeline,          # ใช้ Pipeline
    param_grid=paragrid,
    cv=5,
    scoring='accuracy',
    n_jobs=-1
)
```

```
grid_search.fit(x_train, y_train)
```

# 4. แสดงผลลัพธ์

```
print("Best Parameters:", grid_search.best_params_)
print(f"Best Score: {grid_search.best_score_:.5f}")
```

# ตรวจสอบประสิทธิภาพบนชุดข้อมูลจริง

```
print(f"Grid Search - Train Score: {grid_search.score(x_train, y_train):.5f}")
print(f"Grid Search - Test Score: {grid_search.score(x_test, y_test):.5f}")
```

```
*** Best Parameters: {'model__C': 10, 'model__penalty': 'l1', 'model__solver': 'liblinear'}
Best Score: 0.87018
Grid Search - Train Score: 0.87427
Grid Search - Test Score: 0.87861
```





## 5. Analysis/Model Development

### Workflow– Model Development (Parameter / Hyperparameter Tuning with Pipeline and GridsearchCV – CV Experiment - 1)

Parameter / Hyperparameter Tuning การค้นหาชุดของค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล

```
import pandas as pd
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

# 1. กำหนดขั้นตอนใน Pipeline (เหมือนเดิม)
steps = [
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(random_state=0))
]
pipeline = Pipeline(steps)

# 2. กำหนด Hyperparameters สำหรับ Grid Search (เหมือนเดิม)
paragrid = {
    'model__C': [0.0001, 0.001, 0.01, 0.1, 1, 10, 100, 1000],
    'model__penalty': ['l1', 'l2'],
    'model__solver': ['liblinear']
}

# 3. กำหนดรายการค่า CV ที่ต้องการทดสอบ
cv_values = [2, 3, 4, 5, 6, 7, 8, 9, 10]
```

```
# 4. วนลูปเพื่อรัน GridSearchCV สำหรับแต่ละค่า CV
# -----
best_results = []

for cv_val in cv_values:
    print(f"\n--- Running GridSearchCV with cv = {cv_val} ---")
```

```
    # สร้าง Grid Search สำหรับค่า cv_val นั้นๆ
    grid_search = GridSearchCV(
        pipeline,
        param_grid=paragrid,
        cv=cv_val, # เปลี่ยนค่า cv ตามลูป
        scoring='accuracy',
        n_jobs=-1
    )
```

```
    # ฝึกฝนและค้นหาพารามิเตอร์ที่ดีที่สุดสำหรับ cv_val นี้
    grid_search.fit(x_train, y_train)
```

```
    # เก็บผลลัพธ์ที่ดีที่สุดของรอบนี้
    best_results.append({
        'cv': cv_val,
        'best_params': grid_search.best_params_,
        'best_score': grid_search.best_score_,
        'train_score': grid_search.score(x_train, y_train),
        'test_score': grid_search.score(x_test, y_test)
    })
```

```
    # แสดงผลลัพธ์ย่อย
    print(f"Best Parameters (cv={cv_val}):", grid_search.best_params_)
    print(f"Best Score (cv={cv_val}): {grid_search.best_score_:.5f}")
```

```
# 5. แสดงผลลัพธ์สรุปทั้งหมด
```

```
# -----
print("\n=====")
print("สรุปผลลัพธ์การค้นหา CV ทั้งหมด")
print("=====")
```

```
summary_df = pd.DataFrame(best_results)
print(summary_df[['cv', 'best_score', 'best_params', 'test_score']])
```

```
# ตัวอย่างการหาค่า cv ที่ให้ Test Score สูงสุด
best_overall = summary_df.loc[summary_df['test_score'].idxmax()]
print("\n*** Overall Best Result (Based on Test Score) ***")
print(f"Optimal CV Value: {best_overall['cv']}")
print(f"Best Hyperparameters: {best_overall['best_params']}")
print(f"Highest Test Score: {best_overall['test_score']:.5f}")
```



## 5. Analysis/Model Development

### Workflow– Model Development (Parameter / Hyperparameter Tuning with Pipeline and GridsearchCV – CV Experiment - 2)

Parameter / Hyperparameter Tuning การค้นหาชุดของค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับโมเดล

```
*** --- Running GridSearchCV with cv = 2 ---
Best Parameters (cv=2): {'model__C': 0.1, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=2): 0.88388

--- Running GridSearchCV with cv = 3 ---
Best Parameters (cv=3): {'model__C': 0.1, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=3): 0.87420

--- Running GridSearchCV with cv = 4 ---
Best Parameters (cv=4): {'model__C': 1, 'model__penalty': 'l1', 'model__solver': 'liblinear'}
Best Score (cv=4): 0.87036

--- Running GridSearchCV with cv = 5 ---
Best Parameters (cv=5): {'model__C': 10, 'model__penalty': 'l1', 'model__solver': 'liblinear'}
Best Score (cv=5): 0.87018

--- Running GridSearchCV with cv = 6 ---
Best Parameters (cv=6): {'model__C': 0.1, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=6): 0.86646

--- Running GridSearchCV with cv = 7 ---
Best Parameters (cv=7): {'model__C': 0.01, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=7): 0.87026

--- Running GridSearchCV with cv = 8 ---
Best Parameters (cv=8): {'model__C': 0.01, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=8): 0.86442

--- Running GridSearchCV with cv = 9 ---
Best Parameters (cv=9): {'model__C': 0.1, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Best Score (cv=9): 0.86234

--- Running GridSearchCV with cv = 10 ---
Best Parameters (cv=10): {'model__C': 1, 'model__penalty': 'l1', 'model__solver': 'liblinear'}
```

```
=====
สรุปผลลัพธ์การค้นหา CV ทั้งหมด
=====
```

	cv	best_score	best_params \
0	2	0.883878	{'model__C': 0.1, 'model__penalty': 'l2', 'mod...
1	3	0.874199	{'model__C': 0.1, 'model__penalty': 'l2', 'mod...
2	4	0.870364	{'model__C': 1, 'model__penalty': 'l1', 'model...
3	5	0.870183	{'model__C': 10, 'model__penalty': 'l1', 'mode...
4	6	0.866457	{'model__C': 0.1, 'model__penalty': 'l2', 'mod...
5	7	0.870260	{'model__C': 0.01, 'model__penalty': 'l2', 'mo...
6	8	0.864423	{'model__C': 0.01, 'model__penalty': 'l2', 'mo...
7	9	0.862338	{'model__C': 0.1, 'model__penalty': 'l2', 'mod...
8	10	0.864329	{'model__C': 1, 'model__penalty': 'l1', 'model...

```
test_score
0 0.855491
1 0.855491
2 0.872832
3 0.878613
4 0.855491
5 0.826590
6 0.826590
7 0.855491
8 0.872832

*** Overall Best Result (Based on Test Score) ***
Optimal CV Value: 5
Best Hyperparameters: {'model__C': 10, 'model__penalty': 'l1', 'model__solver': 'liblinear'}
Highest Test Score: 0.87861
```



## 5. Analysis/Model Development

### Workflow– Model Evaluation

```
from sklearn.metrics import confusion_matrix, classification_report

# 1. โมเดลที่ดีที่สุดจาก Grid Search
best_model = grid_search.best_estimator_

# ใช้ get_params() เพื่อดู Hyperparameters ทั้งหมดของโมเดล
print("Hyperparameters ทั้งหมดของโมเดลที่ดีที่สุด:")
print(best_model.get_params())

# 2. ทำนายผลบนชุดข้อมูลทดสอบ
y_pred = best_model.predict(x_test)

# 3. สร้าง Confusion Matrix
cm = confusion_matrix(y_test, y_pred)
print("\nConfusion Matrix:\n", cm)

# 4. แสดง Classification Report
report = classification_report(y_test, y_pred)
print("\nClassification Report:\n", report)
```

Confusion Matrix:

```
[[83 15]
 [ 6 69]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.93	0.85	0.89	98
1	0.82	0.92	0.87	75
accuracy			0.88	173
macro avg	0.88	0.88	0.88	173
weighted avg	0.88	0.88	0.88	173

**Hyperparameters** ทั้งหมดของโมเดลที่ดีที่สุด:

```
{'memory': None, 'steps': [('scaler', StandardScaler()), ('model', LogisticRegression(C=10, penalty='l1', random_state=0, solver='liblinear'))], 'transform_input': None, 'verbose': False, 'scaler': StandardScaler(), 'model': LogisticRegression(C=10, penalty='l1', random_state=0, solver='liblinear'), 'scaler__copy': True, 'scaler__with_mean': True, 'scaler__with_std': True, 'model__C': 10, 'model__class_weight': None, 'model__dual': False, 'model__fit_intercept': True, 'model__intercept_scaling': 1, 'model__l1_ratio': None, 'model__max_iter': 100, 'model__multi_class': 'deprecated', 'model__n_jobs': None, 'model__penalty': 'l1', 'model__random_state': 0, 'model__solver': 'liblinear', 'model__tol': 0.0001, 'model__verbose': 0, 'model__warm_start': False}
```



## 5. Analysis/Model Development

### Workflow– Model Evaluation

#### Confusion Matrix และ Classification Report

Confusion Matrix:

```
[[83 15]
 [ 6 69]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.93	0.85	0.89	98
1	0.82	0.92	0.87	75
accuracy			0.88	173
macro avg	0.88	0.88	0.88	173
weighted avg	0.88	0.88	0.88	173

#### ประสิทธิภาพและการทำงานของแบบจำลอง (Model Performance and Discussion)

##### ประสิทธิภาพโดยรวม (Overall Performance)

ผลลัพธ์จากโมเดลการพยากรณ์นี้แสดงให้เห็นว่าโมเดลมีความสามารถในการจำแนกผู้ขอสินเชื่อบัตรเครดิตได้อย่างแม่นยำและสมดุล โดยมี Accuracy รวมอยู่ที่ 88% จาก 173 ตัวอย่างในชุดทดสอบ ซึ่งสูงกว่าเกณฑ์ที่ยอมรับได้สำหรับงานจำแนกประเภท

##### การประเมินความเสี่ยงจาก Confusion Matrix

ผลลัพธ์	ค่า	ความหมายเชิงธุรกิจ (Business Problem: ลดความเสี่ยง)
True Negative (TN)	83	โมเดลทำนายถูกว่า 'ปฏิเสธ' และค่าจริงคือ 'ปฏิเสธ' (ดีมาก: ป้องกันการอนุมัติที่ไม่ควรเกิด)
True Positive (TP)	69	โมเดลทำนายถูกว่า 'อนุมัติ' และค่าจริงคือ 'อนุมัติ' (ดีมาก: เพิ่มโอกาสทางธุรกิจ)
False Positive (FP)	15	ความเสี่ยงทางการเงิน: โมเดลทำนายผิดว่า 'อนุมัติ' ทั้งที่ค่าจริงคือ 'ปฏิเสธ' (นำไปสู่ หนี้เสีย โดยตรง)
False Negative (FN)	6	การสูญเสียโอกาส: โมเดลทำนายผิดว่า 'ปฏิเสธ' ทั้งที่ค่าจริงคือ 'อนุมัติ' (ทำให้พลาดลูกค้าดีๆ)



## 5. Analysis/Model Development

### Workflow– Model Evaluation

#### Confusion Matrix และ Classification Report

Confusion Matrix:

```
[[83 15]
 [ 6 69]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.93	0.85	0.89	98
1	0.82	0.92	0.87	75
accuracy			0.88	173
macro avg	0.88	0.88	0.88	173
weighted avg	0.88	0.88	0.88	173

#### ประสิทธิภาพแยกตามคลาส (Classification Report Details)

Metric	Class 0 (ปฏิเสธ)	Class 1 (อนุมัติ)	อภิปรายเชิงธุรกิจ
Precision	0.93	0.82	เมื่อโมเดลทำนาย 'ปฏิเสธ' ความแม่นยำสูงมาก (93%) แต่การทำนาย 'อนุมัติ' ความแม่นยำลดลงเหลือ 82% (สะท้อนค่า FP = 15)
Recall	0.85	0.92	โมเดลสามารถระบุลูกค้าที่ควร 'อนุมัติ' ได้ถึง 92% (FN ต่ำ: 6) แต่การระบุลูกค้าที่ควร 'ปฏิเสธ' อยู่ที่ 85% (FP/FN: 15/6)
F1-Score	0.89	0.87	ค่าสมดุลที่ดี แต่ประสิทธิภาพในการทำนายคลาส 'ปฏิเสธ' (Class 0) ยังคงสูงกว่าเล็กน้อย

### บทสรุปของโมเดล

โมเดลนี้มีประสิทธิภาพดีและสามารถนำไป Deploy เพื่อใช้ในการตัดสินใจอนุมัติเบื้องต้นโดยอัตโนมัติได้ตาม Value Proposition ของโครงการ อย่างไรก็ตาม ควรเน้นการปรับปรุง Precision ของ Class 1 ให้สูงขึ้นเพื่อลดความเสี่ยงหนี้เสีย (FP) ให้สอดคล้องกับวัตถุประสงค์ทางธุรกิจหลักของสถาบันการเงิน



## 5. Analysis/Model Development

### Workflow– Model Development (Selected Parameter with Pipeline and GridsearchCV )

```
print(x.shape)
x.head()
```

(690, 4)

	YearsEmployed	PriorDefault	Employed	CreditScore
--	---------------	--------------	----------	-------------

0	1.250	1	1	1
1	3.750	1	1	5
2	1.500	1	1	2
3	0.165	0	0	0
4	0.000	1	0	0

```
print(y.shape)
y.head()
```

(690,)

	Approved
--	----------

0	1
1	1
2	1
3	1
4	0

Confusion Matrix:

```
[[78 20]
 [ 5 70]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.94	0.80	0.86	98
1	0.78	0.93	0.85	75
accuracy			0.86	173
macro avg	0.86	0.86	0.86	173
weighted avg	0.87	0.86	0.86	173

#### Hyperparameters ทั้งหมดของโมเดลที่ดีที่สุด:

```
{'memory': None, 'steps': [('scaler', StandardScaler()), ('model', LogisticRegression(C=0.01, penalty='l1', random_state=0, solver='liblinear'))], 'transform_input': None, 'verbose': False, 'scaler': StandardScaler(), 'model': LogisticRegression(C=0.01, penalty='l1', random_state=0, solver='liblinear'), 'scaler__copy': True, 'scaler__with_mean': True, 'scaler__with_std': True, 'model__C': 0.01, 'model__class_weight': None, 'model__dual': False, 'model__fit_intercept': True, 'model__intercept_scaling': 1, 'model__l1_ratio': None, 'model__max_iter': 100, 'model__multi_class': 'deprecated', 'model__n_jobs': None, 'model__penalty': 'l1', 'model__random_state': 0, 'model__solver': 'liblinear', 'model__tol': 0.0001, 'model__verbose': 0, 'model__warm_start': False}
```



## 5. Analysis/Model Development

### Workflow– Model Development (Selected Parameter with Pipeline and GridsearchCV )

```
print(x.shape)
x.head()
```

(690, 1)

CreditScore

0	1
1	5
2	2
3	0
4	0

```
print(y.shape)
y.head()
```

(690,)

Approved

0	1
1	1
2	1
3	1
4	0

Confusion Matrix:

```
[[94  4]
 [37 38]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.72	0.96	0.82	98
1	0.90	0.51	0.65	75
accuracy			0.76	173
macro avg	0.81	0.73	0.74	173
weighted avg	0.80	0.76	0.75	173

#### Hyperparameters ทั้งหมดของโมเดลที่ดีที่สุด:

```
{'memory': None, 'steps': [('scaler', StandardScaler()), ('model', LogisticRegression(C=0.1, penalty='l1', random_state=0, solver='liblinear'))], 'transform_input': None, 'verbose': False, 'scaler': StandardScaler(), 'model': LogisticRegression(C=0.1, penalty='l1', random_state=0, solver='liblinear'), 'scaler__copy': True, 'scaler__with_mean': True, 'scaler__with_std': True, 'model__C': 0.1, 'model__class_weight': None, 'model__dual': False, 'model__fit_intercept': True, 'model__intercept_scaling': 1, 'model__l1_ratio': None, 'model__max_iter': 100, 'model__multi_class': 'deprecated', 'model__n_jobs': None, 'model__penalty': 'l1', 'model__random_state': 0, 'model__solver': 'liblinear', 'model__tol': 0.0001, 'model__verbose': 0, 'model__warm_start': False}
```



## 6. Findings and Insights

### ข้อสรุปเชิงธุรกิจ (Data Analytics)

1. บทสรุปเชิงวิเคราะห์: ปัจจัยด้าน ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผล การตัดสินใจอนุมัติบัตรเครดิต ซึ่งตอบคำถามเชิงวิเคราะห์ที่ว่า "คุณลักษณะใดของผู้สมัครมีความสัมพันธ์กับการอนุมัติมากที่สุด"

2. การแบ่งกลุ่มลูกค้าตามความเสี่ยง (Customer Segmentation) โดยการทดสอบ T-test สามารถตอบคำถามที่ว่า “มีกลุ่มลูกค้าที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันอย่างชัดเจน หรือไม่” กล่าวคือ

- กลุ่มความเสี่ยงต่ำ (Low-Risk/Approved Group): ลูกค้าที่ได้รับอนุมัติมี Credit Score เฉลี่ยสูงถึง 4.61 สะท้อนให้เห็นว่ากลุ่มนี้มีประวัติทางการเงินที่ดีและตรงตามเกณฑ์หลักของธนาคารอย่างชัดเจน

- กลุ่มความเสี่ยงสูง (High-Risk/Not Approved Group): ลูกค้าที่ไม่ได้รับการอนุมัติมี Credit Score เฉลี่ยต่ำมากที่ 0.63 แสดงให้เห็นว่ากลุ่มนี้มีโปรไฟล์ความเสี่ยงสูงมาก และถูกปฏิเสธอย่างชัดเจน

บทสรุปเชิงวิเคราะห์ : ปัจจุบัน Credit Score เป็นปัจจัยขับเคลื่อนหลัก (Primary Driver) ในกระบวนการอนุมัติ ทำให้เกิดการแบ่งกลุ่มลูกค้าเป็นสองขั้วอย่างมีประสิทธิภาพ





## 6. Findings and Insights

### ข้อสรุปเชิงธุรกิจ (Data Science)

#### การเชื่อมโยงกับปัญหาและจุดประสงค์โครงการ

##### 1. การแก้ปัญหาและวัตถุประสงค์ (Problem Solving and Objectives)

- Problem: กระบวนการพิจารณาใช้เวลานานและมีความเสี่ยงจากดุลยพินิจ
- Solution/Value Proposition: โมเดลนี้สามารถให้ผลการตัดสินใจเบื้องต้นที่รวดเร็ว (Operational Impact) และ เป็นกลาง ด้วย Accuracy 88%, โมเดลสามารถตัดสินใจโดยอัตโนมัติได้อย่างน่าเชื่อถือในกรณีส่วนใหญ่ ลดเวลาในการตัดสินใจจากชั่วโมง/วัน เหลือเพียงวินาที

##### 3.การเพิ่มโอกาสทางธุรกิจ (Business Opportunity)

- โมเดลมี False Negative (FN) = 6 และ Recall สำหรับ Class 1 (อนุมัติ) คือ 0.92
- โมเดลพลาดโอกาสที่จะอนุมัติลูกค้าที่มีคุณภาพจริง (FN) เพียงเล็กน้อย (6 ครั้ง) ซึ่งแสดงว่าโมเดลมีการรักษาลูกค้าที่ดี (Good Customer Acquisition) ได้อย่างมีประสิทธิภาพ

##### 2. การลดความเสี่ยง (Business Problem: Default Rate Reduction)

- วัตถุประสงค์คือ ลดความเสี่ยงทางการเงิน (หนี้เสีย) ซึ่งต้องการให้ False Positive (FP) ต่ำที่สุด
- โมเดลมี FP = 15 และ Precision สำหรับ Class 1 (อนุมัติ) คือ 0.82 หมายความว่าในทุกๆ 100 ครั้งที่โมเดลบอกว่า "อนุมัติ" จะมีประมาณ 18 ครั้ง ที่เป็นการทำนายผิดพลาดและอาจกลายเป็นหนี้เสีย ซึ่งเป็นจุดที่ควรปรับปรุง
- Action/Recommendation: ควรพิจารณา ปรับ Threshold ของโมเดลให้มีความระมัดระวังมากขึ้น (Bias ไปทาง Class 0/ปฏิเสธ) เพื่อลดค่า FP ลงอีก แม้ว่าจะต้องแลกมาด้วยการเพิ่ม FN เล็กน้อยก็ตาม (Trade-off ระหว่าง Precision และ Recall)

**บทสรุปเชิงวิเคราะห์:** โมเดลนี้มีประสิทธิภาพดีมากและสามารถนำไป Deploy เพื่อใช้ในการตัดสินใจอนุมัติเบื้องต้นโดยอัตโนมัติได้ตาม Value Proposition ของโครงการ อย่างไรก็ตาม ควรเน้นการปรับปรุง Precision ของ Class 1 ให้สูงขึ้นเพื่อลดความเสี่ยงหนี้เสีย (FP) ให้สอดคล้องกับวัตถุประสงค์ทางธุรกิจหลักของสถาบันการเงิน



## 7. Conclusion and Recommendation/Action and Impact

<div><div>1. Problem Statement/Background</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• What do we know about?</div><div>สถาบันการเงินอนุมัติ/ปฏิเสธการสมัครบัตรเครดิต โดยพิจารณาจากข้อมูลผู้สมัคร โดยกระบวนการพิจารณาอาจใช้เวลานานและขึ้นอยู่กับดุลยพินิจของนักวิเคราะห์สินเชื่อ ซึ่งอาจนำไปสู่ความเสี่ยงหรือการสูญเสียโอกาสทางธุรกิจ</div><div>• What problem are you trying to solve?</div><div>การสร้างแบบจำลองเพื่อทำนายผลการอนุมัติบัตรเครดิตโดยอัตโนมัติ เพื่อเพิ่มความรวดเร็วและความแม่นยำในการตัดสินใจ</div><div>• What is the business problem?</div><div>การลดความเสี่ยงทางการเงิน (อัตราการผิดนัดชำระหนี้ - Default Rate) และเพิ่มประสิทธิภาพในการดำเนินงาน (Operational Efficiency) ของฝ่ายอนุมัติสินเชื่อ</div><div>• Who are the stakeholders?</div><div>ธนาคาร/สถาบันการเงิน (ฝ่ายบริหารความเสี่ยง, ฝ่ายการตลาด, ฝ่ายปฏิบัติการ) ทีม Data Scientist/Analyst ผู้สมัครบัตรเครดิต</div></div></div></div></div></div>	<div><div>2. Questions/Hypothesis</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• Analytical Questions</div><div>- คุณลักษณะใดของผู้สมัคร (เช่น อายุ, รายได้, ประเภทงาน) ที่มีความสัมพันธ์กับการอนุมัติมากที่สุด?</div><div>- มีกลุ่มลูกค้า (Segments) ที่มีความเสี่ยงสูง/ต่ำ ที่แตกต่างกันชัดเจนหรือไม่? เกณฑ์การตัดสินใจแบบเดิมมีข้อบกพร่องตรงไหนบ้าง?</div></div><div><div><div>• Predictive Hypothesis (What can we predict?)</div><div>- เราสามารถทำนายผลการอนุมัติบัตรเครดิต (Approved หรือ Rejected) จากข้อมูลของผู้สมัครที่ให้มาด้วยความแม่นยำสูง เพื่อช่วยในการตัดสินใจอัตโนมัติ</div></div><div><div><div>• SMART Objectives</div><div>- เพิ่มยอดสินเชื่อ จากการอนุมัติบัตรเครดิต อย่างน้อย 5% ภายใน 1 ปี ด้วยการปรับกลยุทธ์ด้านสินเชื่อ</div></div></div></div></div></div></div></div>	<div><div>3. Value Propositions</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• What are we trying to do for the end-user(s) of the system?</div><div>มอบเครื่องมือในการตัดสินใจที่รวดเร็ว เป็นกลาง และสม่ำเสมอให้กับเจ้าหน้าที่สินเชื่อ ทำให้ผู้สมัครได้รับผลการตัดสินใจที่รวดเร็วยิ่งขึ้น</div></div><div><div><div>• What objectives are we serving?</div><div>เพิ่มประสิทธิภาพการดำเนินงาน (ลดต้นทุนและเวลา) ปรับปรุงการประเมินความเสี่ยง (ลดหนี้เสีย) ขยายฐานลูกค้าอย่างมีคุณภาพ</div></div></div></div></div></div></div>	<div><div>4. Data Sources/Attributes</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• Data sources &amp; collection</div><div>- Kaggle Dataset: "Credit Card Approvals (Clean Data)" (ซึ่งจำลองมาจากการสมัครบัตรเครดิต)</div><div>- ข้อมูลในทางปฏิบัติ: ฐานข้อมูลภายในของธนาคาร/สถาบันการเงิน (ข้อมูลการสมัคร, ประวัติสินเชื่อ, ข้อมูลเครดิตบูโร)</div></div><div><div><div>• Data cleaning &amp; preprocessing</div><div>- เนื่องจากเป็น "Clean Data" จะเน้นการตรวจสอบขั้นสุดท้าย การจัดการกับค่าที่หายไป (Missing Values) ที่ยังอาจมีอยู่</div><div>- การเข้ารหัสข้อมูลประเภท Categorical (เช่น One-Hot Encoding) การปรับขนาดข้อมูลตัวเลข (Normalization/ Standardization)</div></div><div><div><div>• Target variables &amp; feature</div><div>- Target Variable: สถานะการอนุมัติ (Approved: '+', Rejected: '-')</div><div>- Features: คุณลักษณะของผู้สมัคร เช่น อายุ, รายได้, หนี้สิน, สถานภาพ, ประวัติเครดิต, ประเภทงาน (ตามคุณลักษณะใน Dataset)</div></div><div><div><div>• Encoding &amp; scaling strategies</div><div>- Encoding: ข้อมูลที่ไม่ใช่ตัวเลข (Non-numerical/Categorical Data) ให้กลายเป็นตัวเลข โดยใช้เทคนิคที่เรียกว่า Label Encoding</div><div>- Scaling: Standard Scaler สำหรับตัวแปรตัวเลข (Numerical)</div></div></div></div></div></div></div></div></div>
<div><div>5. Analysis/Model Development</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• Analytics Methodology</div><div>- EDA techniques: การวิเคราะห์ความถี่และค่าสถิติเชิงพรรณนา (Univariate/Bivariate Analysis) เพื่อดูความสัมพันธ์ของแต่ละคุณลักษณะกับผลการอนุมัติ</div><div>- Visualization strategy: Heatmap สำหรับ Correlation Matrix</div><div>- Segmentation approach: การจัดกลุ่มลูกค้าตามโปรไฟล์ความเสี่ยง (Risk Profiles)</div></div><div><div><div>• Modeling Methodology</div><div>- Algorithm selection: Classification Algorithms - Logistic Regression</div></div></div><div><div><div>- Training, hyperparameter tuning, evaluation metric:</div><div>** Training: แบ่งข้อมูลเป็น Training, และ Test Sets (Cross-Validation)</div><div>** Tuning: Grid Search เพื่อหา Hyperparameters ที่เหมาะสมที่สุด</div></div></div></div></div></div></div>	<div><div>6. Findings and Insights</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• Business Insights</div><div>- คุณลักษณะหลักที่ขับเคลื่อนผลการอนุมัติ (Feature Importance)</div><div>- คำตอบ ปัจจัยด้าน ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผลการตัดสินใจอนุมัติบัตรเครดิต</div></div><div><div><div>- ระบูกกลุ่มลูกค้าที่มีความเสี่ยงสูง/ต่ำ ที่ชัดเจนในชุดข้อมูล</div><div>* คำตอบ ข้อสรุปเชิงธุรกิจ: ปัจจุบัน Credit Score เป็นปัจจัยขับเคลื่อนหลัก (Primary Driver) ในกระบวนการอนุมัติ ทำให้เกิดการแบ่งกลุ่มลูกค้าเป็นสองขั้วอย่างมีประสิทธิภาพ</div></div><div><div><div>- แนวโน้มและรูปแบบของผู้สมัครที่ถูกอนุมัติ/ปฏิเสธ</div><div>* คำตอบ ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed) เป็นคุณลักษณะหลักที่ขับเคลื่อนผลการตัดสินใจอนุมัติบัตรเครดิต ซึ่งตอบคำถามเชิงวิเคราะห์ที่ว่า "คุณลักษณะใดของผู้สมัครมีความสัมพันธ์กับการอนุมัติมากที่สุด"</div></div></div></div><div><div><div><div>• Predictive Results</div><div>- ประสิทธิภาพของแบบจำลองที่ดี (F1-Score = 0.88)</div><div>รายชื่อคุณลักษณะที่มีความสำคัญสูงสุด 4 อันดับแรกในการทำนายผล ประวัติความเสี่ยง (PriorDefault) และ ความมั่นคง (Employed, CreditScore, YearsEmployed)</div><div>- ผลการทดสอบกับ Test Set ที่ไม่ได้ใช้ในการฝึกฝน (Score = 0.88)</div></div></div></div></div></div></div></div>	<div><div>7. Recommendation/Action and Impact</div><div><div><div><div></div><div></div></div><div><div></div><div></div></div></div><div><div><div><div>• What should we do with the findings?</div><div>- Action: นำแบบจำลองที่ปรับปรุงแล้วไปใช้งาน (Deploy) ในรูปแบบของ API หรือ Service เพื่อให้ระบบของธนาคารสามารถเรียกใช้ในการตัดสินใจอนุมัติเบื้องต้นโดยอัตโนมัติ</div></div><div><div><div>• What are the impacts?</div><div>- Operational Impact: ลดเวลาในการตัดสินใจจากชั่วโมง/วัน เหลือเพียงวินาที</div><div>- Business Impact: ลดการเกิดหนี้เสีย (ลดความเสี่ยง) เนื่องจากมีความแม่นยำในการคัดกรองมากขึ้น และเพิ่มโอกาสในการอนุมัติลูกค้าที่มีคุณภาพเร็วขึ้น (เพิ่มกำไร)</div><div>- Customer Impact: ผู้สมัครได้รับผลการตัดสินใจรวดเร็วขึ้น ทำให้ประสบการณ์การใช้งานดีขึ้น</div></div></div></div></div></div></div>	



# THANK YOU

[14 ธันวาคม 2568]